데이터 분석 및 시각화

pandas / matplotlib

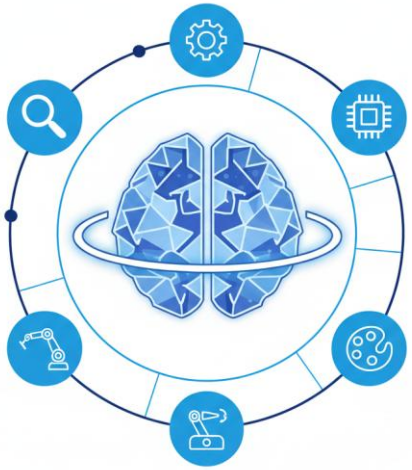

아나콘다(Anaconda) 플랫폼

❖ **Anaconda Download**

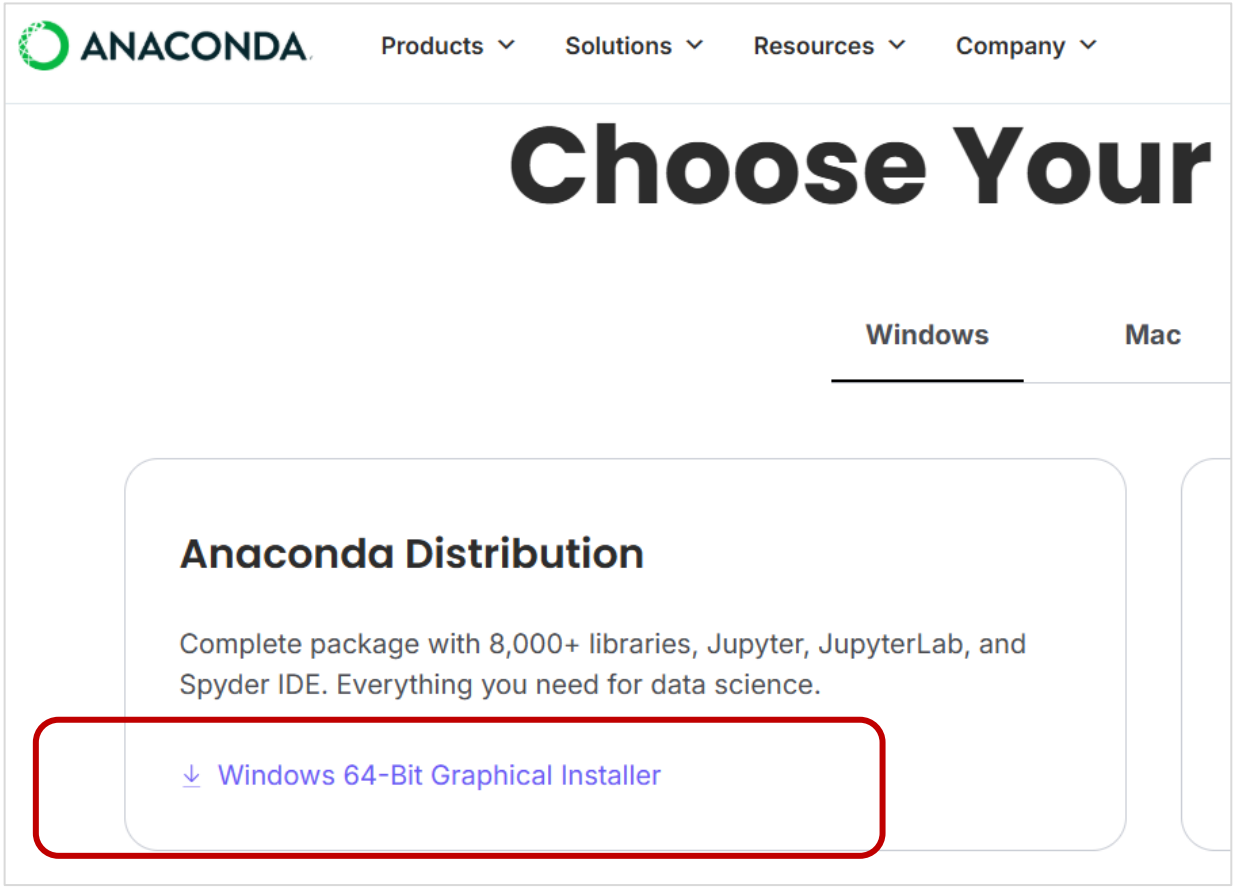

아나콘다(Anaconda) 플랫폼

❖ 주피터 노트북(Jupyter Notebook) IDE 실행

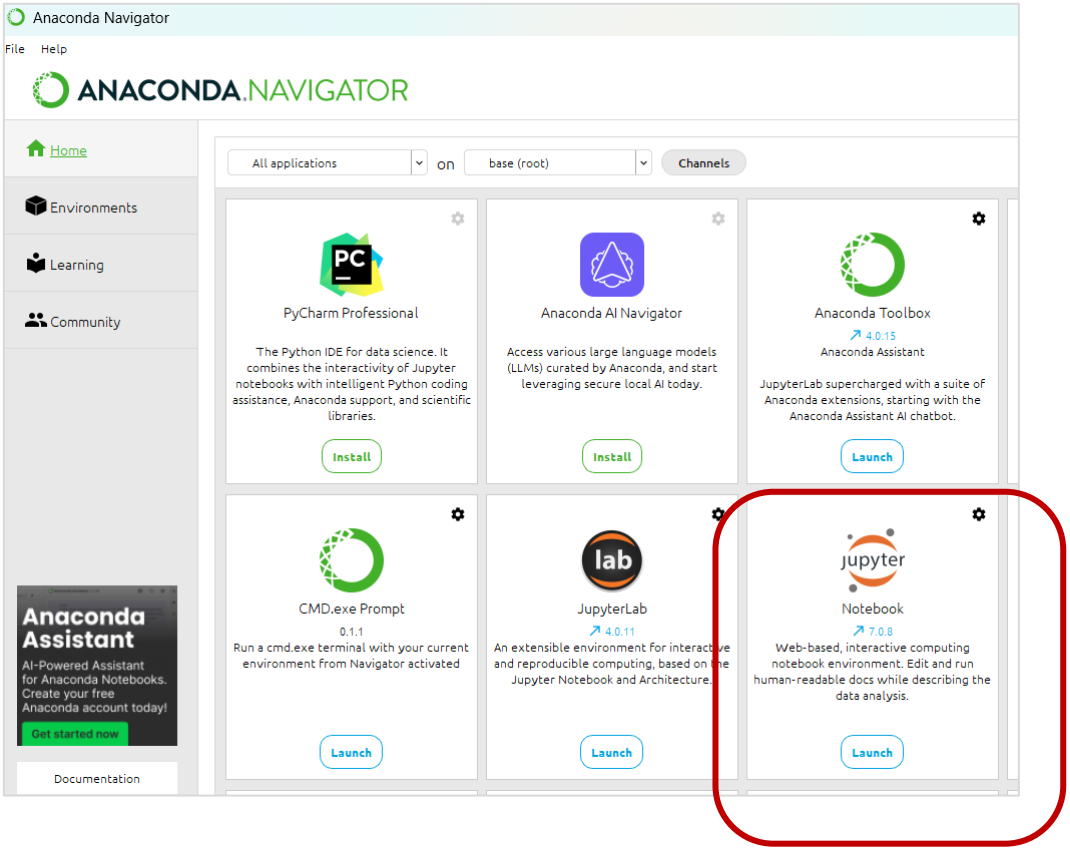

주피터 노트북(Jupyter Notebook)

❖ 작업 디렉터리 생성

New > New Folder > dataworks 폴더 생성 > 하위에 datas 폴더 생성

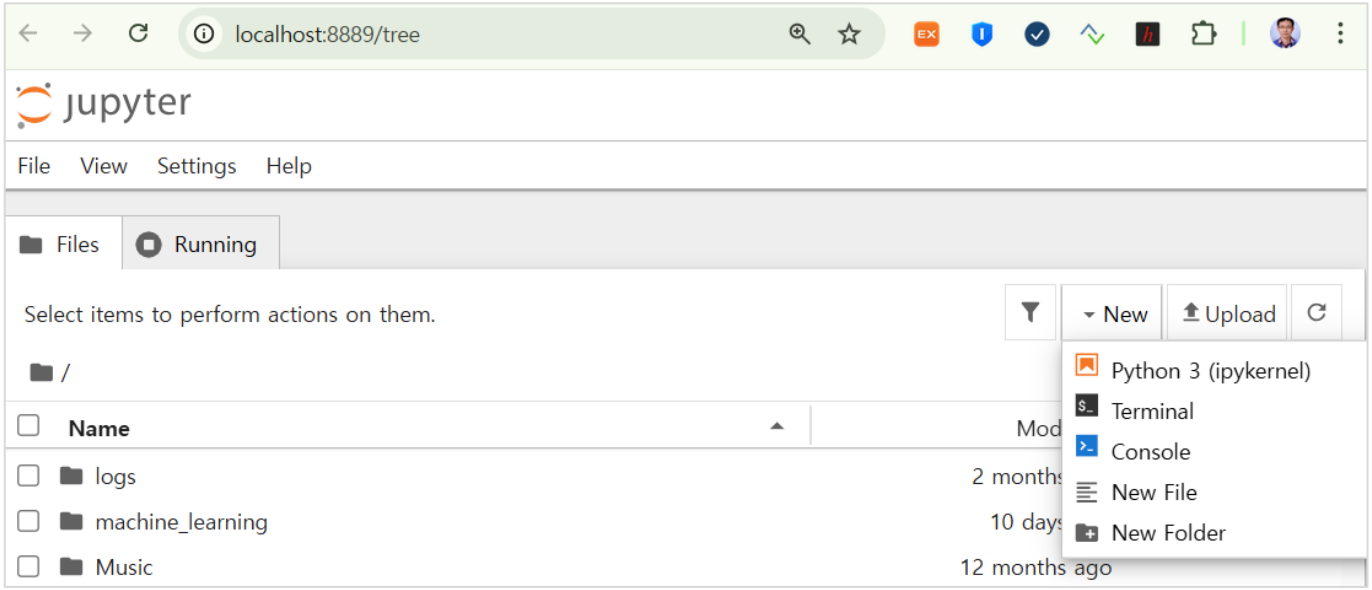

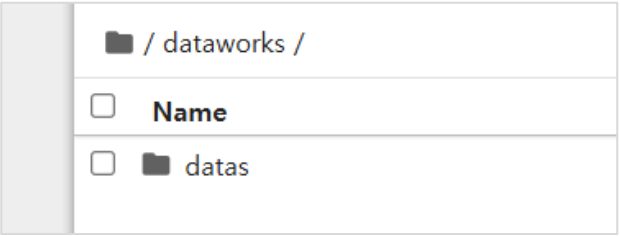

주피터 노트북(Jupyter Notebook)

❖ 파일 생성(.ipynb)

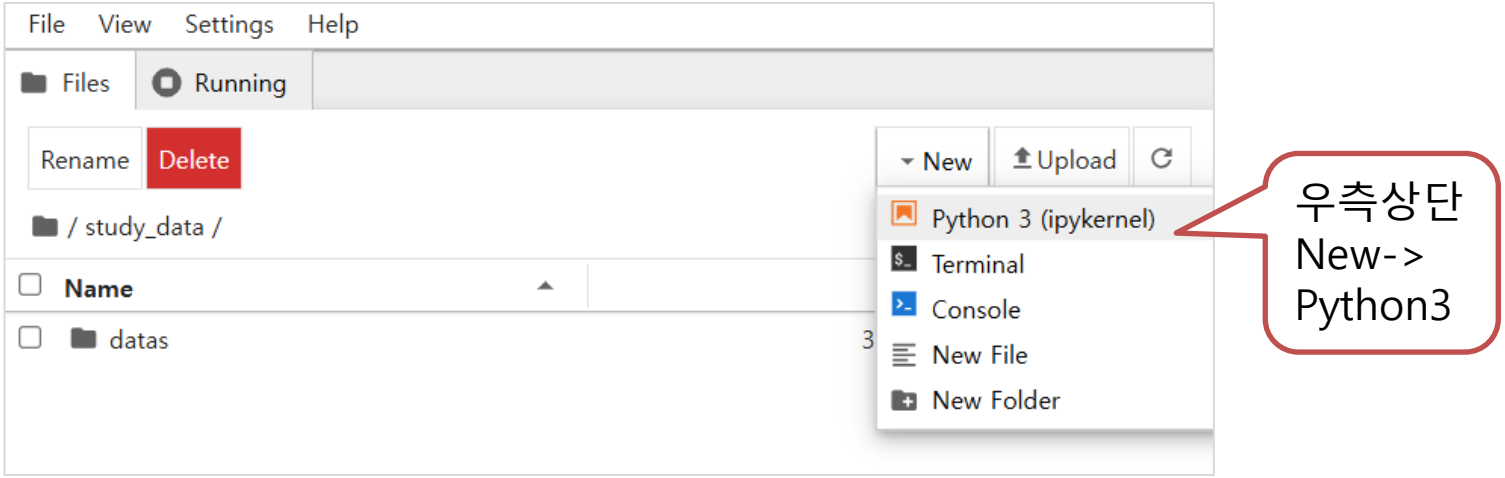

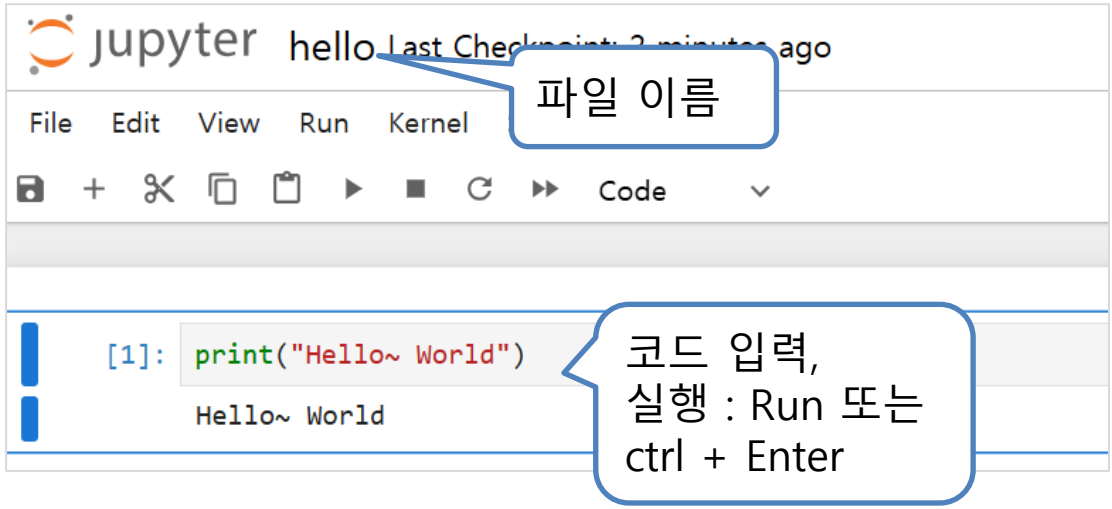

주피터 노트북(Jupyter Notebook)

❖ 코드 입, 출력

```
[1]: print("Hello~ World")

     Hello~ World

[2]: print("안녕~ 세계")

     안녕~ 세계

[7]: 10 + 20
     10 - 20

[7]: -10
```

```
[6]: n1 = 20
     n2 = 10

     print(n1 + n2)
     print(n1 - n2)
     print(n1 * n2)
     print(n1 / n2)
     print(n1 % n2)

     30
     10
     200
     2.0
     0
```

```
[10]: carts = ["계란", "라면", "콩나물"]
      print(carts)

      for cart in carts:
          print(cart)

      ['계란', '라면', '콩나물']
      계란
      라면
      콩나물
```

구글 코렙

❖ 구글 드라이브 > 코렙 설치하기

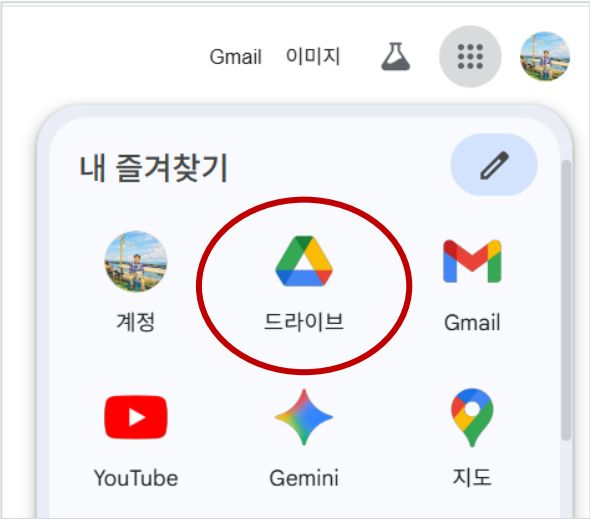

- + 신규 > 연결할 앱 더보기

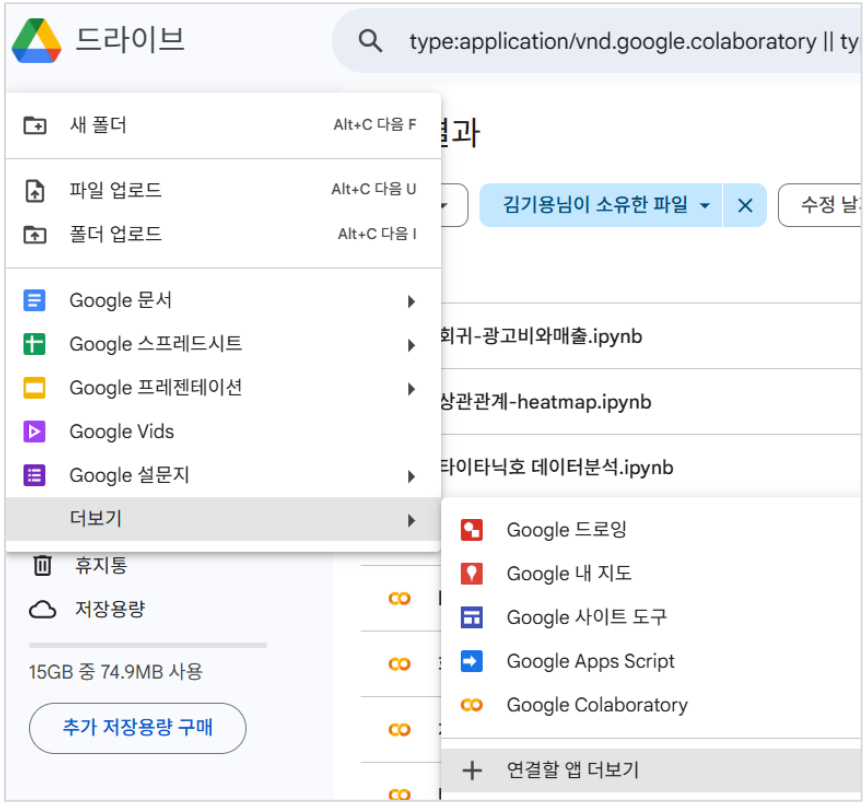

구글 코렙

❖ 구글 드라이브 > 코렙 설치하기

- 연결할 앱 더보기 > colab 검색 > 코렙 설치

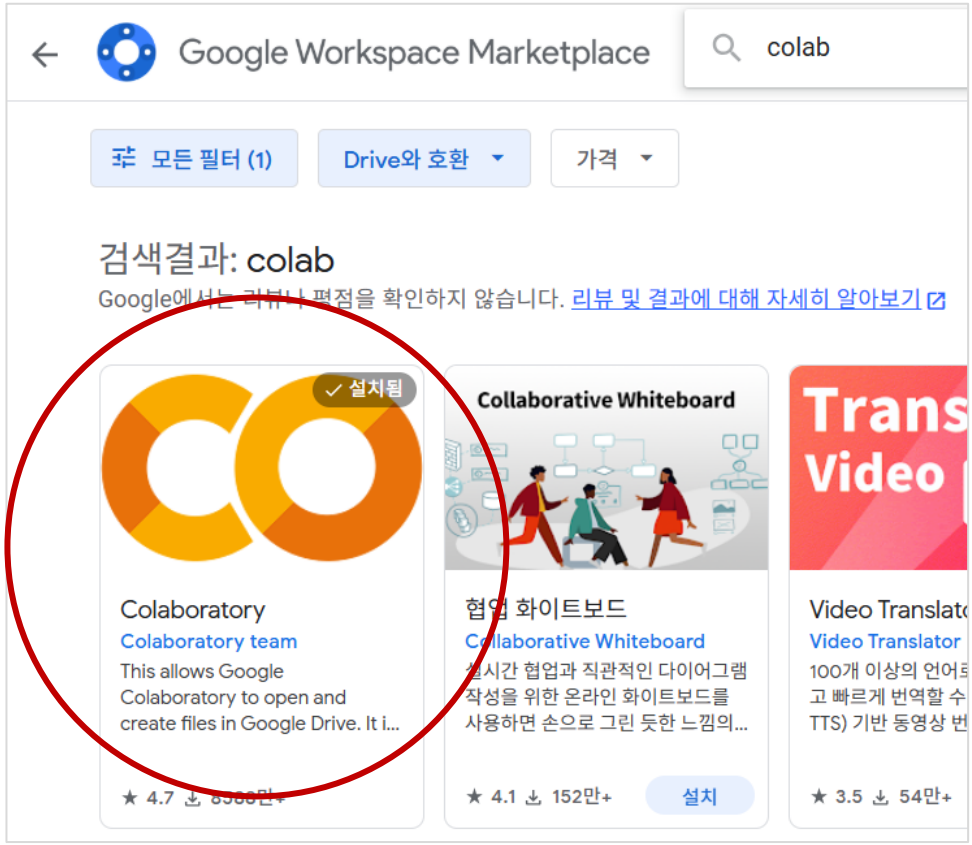

구글 코렙

❖ 새 노트 만들기

- + 신규 > 더보기 > Google Colaboratory

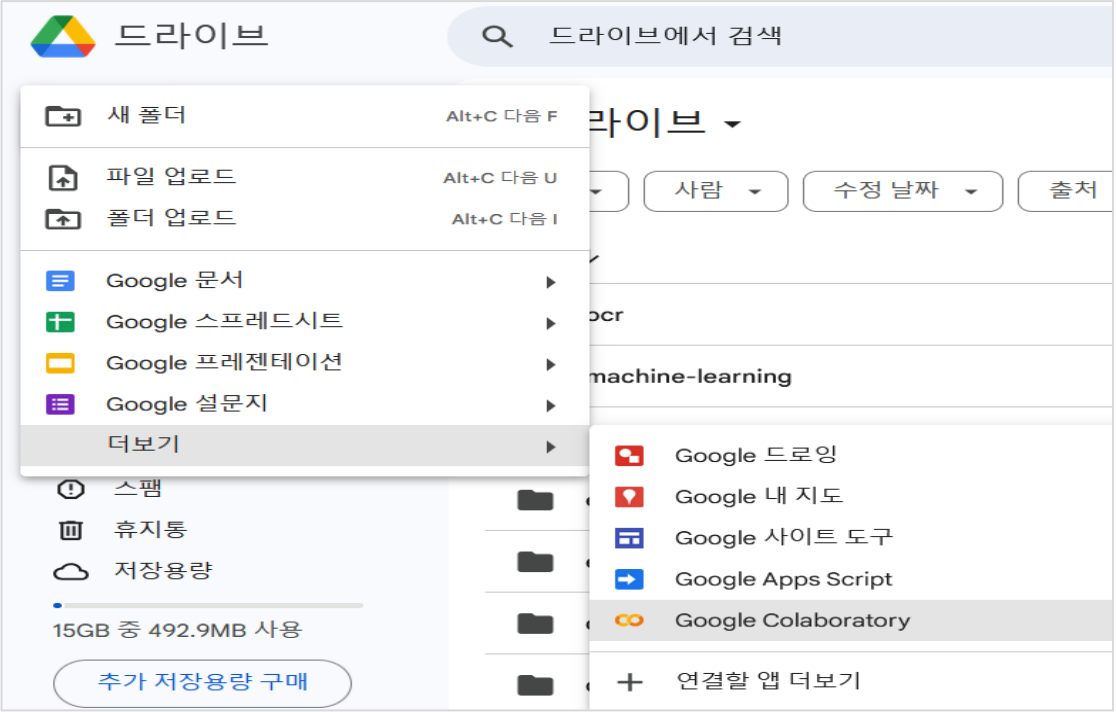

구글 코렙

❖ 새 노트 만들기

- 파일이름 > note01.ipynb

확장자는 .ipynb

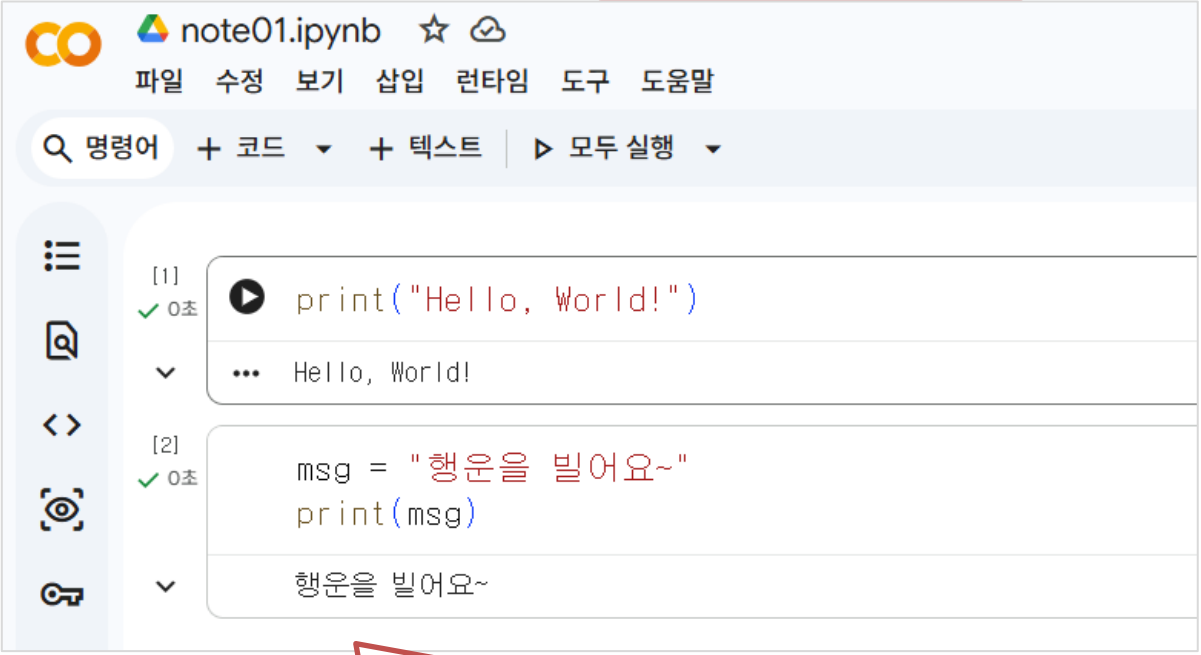

코드 실행 : 실행버튼 또는 ctrl + Enter

❖ 텍스트 사용하기

- 텍스트(버튼) > 문서의 제목이나 소제목을 만들때 사용

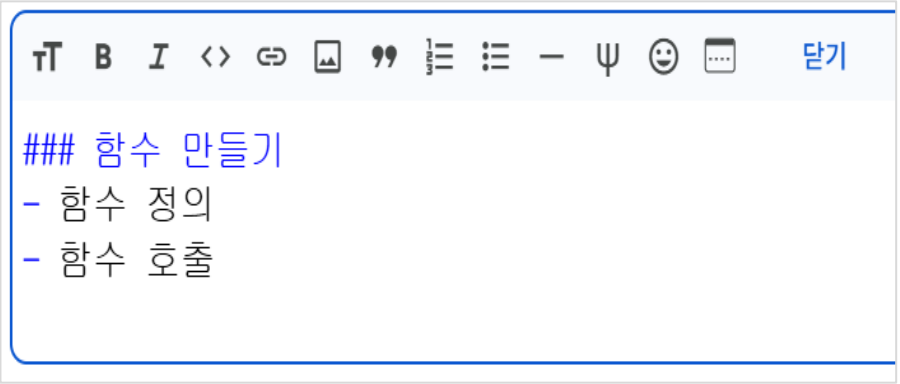

<편집화면>

shift + enter

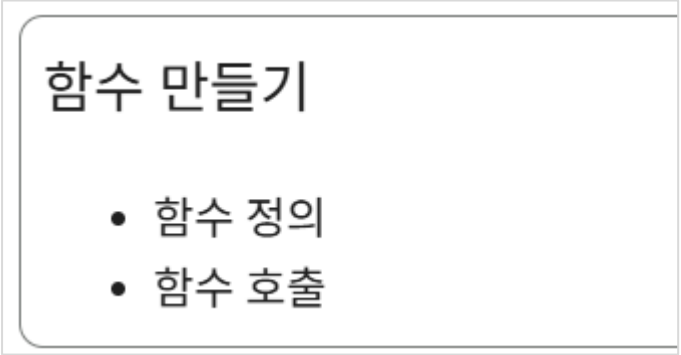

<출력화면>

구글 코렙

❖ 코드 추가

+ 코드 + 텍스트

```
# 절대값 계산 함수 정의
def my_abs(x):
  if x < 0:
    return -x
  else:
    return x

print(my_abs(-12))
```

```
12
```

구글 코렙

❖ AI(Gemini) 지원

- 설정 > AI 지원 > 동의

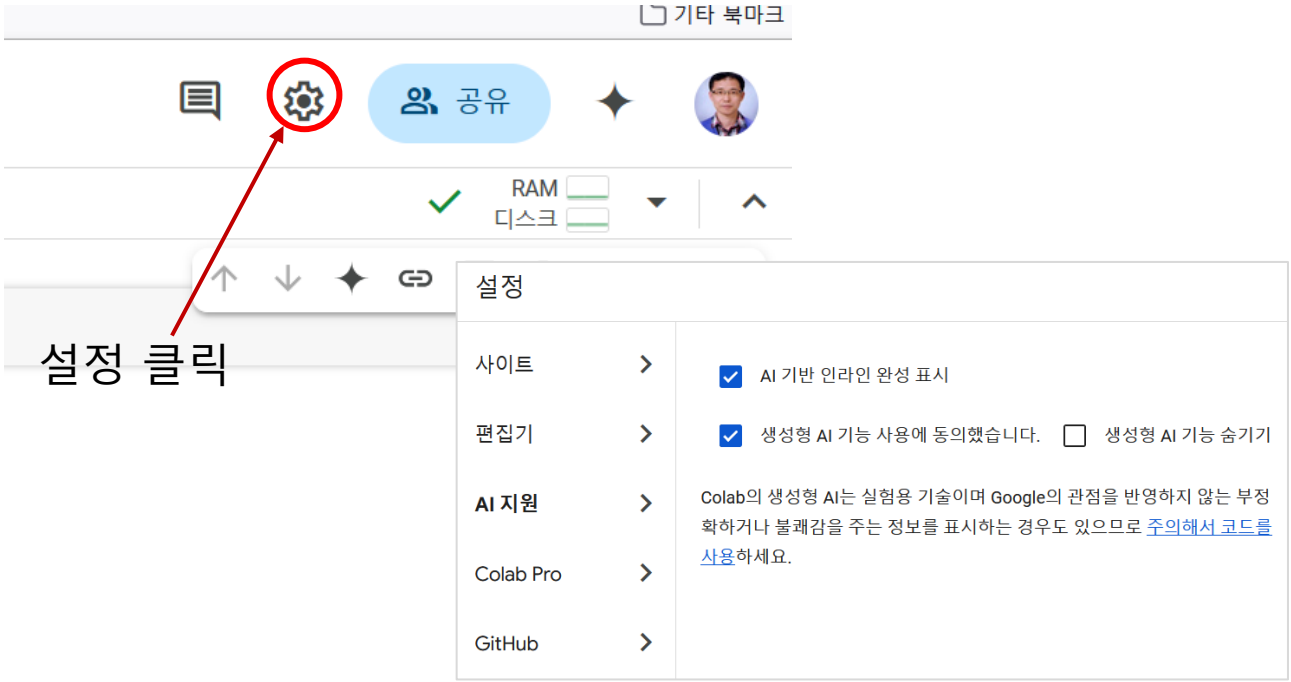

구글 코렙

❖ 새 폴더 만들기 – 이름: 데이터분석

- + 신규 > 새폴더

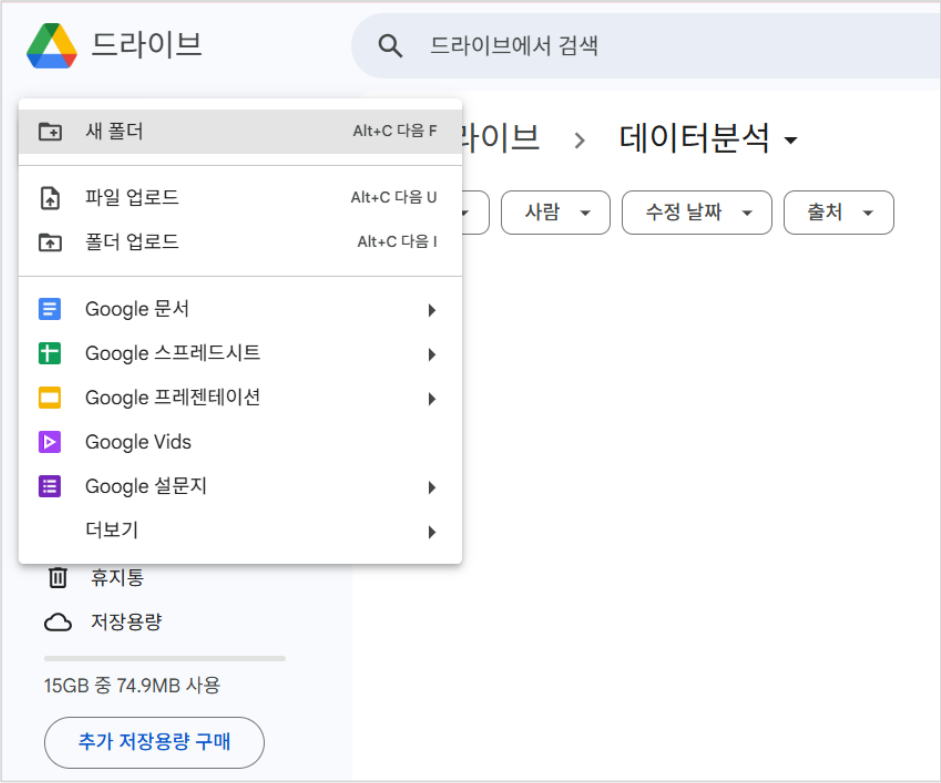

데이터 분석

- **데이터 분석용 주요 라이브러리**

+ 데이터 분석을 위한 주요 라이브러리를 알려줘

라이브러리	주요 역할	핵심 기능
pandas	데이터 분석 핵심	DataFrame, CSV/Excel 처리, 필터링, 그룹화
numpy	수치계산 기반	다차원 배열, 수학/통계 연산, 고속 연산
matplotlib	데이터 시각화	선/막대/산점도 그래프

데이터 분석

- **판다스**
  - 데이터를 수집, 정리하는 데 최적화된 도구로 **표 형태(행·열)의 데이터**를 빠르고 편리하게 처리하기 위한 라이브러리입니다.
  - 가장 인기있는 프로그래밍 언어인 **파이썬(python)**을 기반으로 한다.
  - 시리즈(Series)와 데이터프레임(DataFrame)이라는 구조화된 데이터 형식을 제공한다.
  - 판다스 설치 - **아나콘다 플랫폼**에는 이미 설치되어 있습니다.

    (pip install pandas)

데이터 분석

- **판다스 자료구조**
  - **시리즈(Series)** – 데이터가 순차적으로 나열된 1차원 배열의 형태를 가지며, 인덱스(Index)는 데이터 값(value)과 일대일 대응이 된다.
  - **데이터프레임(DataFrame)** – 행(Row)과 열(Column)로 만들어지는 2차원 배열 구조로 표(Table) 형태이다.

	제품명
0	키보드
1	마우스
2	USB 메모리

인덱스 (index)

[시리즈]

	제품명	가격
0	키보드	20,000
1	마우스	32,000
2	USB 메모리	10,000

칼럼 (column)

[데이터프레임]

데이터 분석

- **Series(시리즈)**

import pandas as pd(별칭)

pd.Series(데이터, 인덱스)

속성	기능
index	- 시리즈의 인덱스 (생략하면 기본 0, 1, 2)
values	- 시리즈의 값(요소)
shape	- 시리즈의 크기 (요소의수,)

데이터 분석

- **Series(시리즈)**

```
import pandas as pd

data = ['키보드', '마우스', 'USB 메모리']

# Series 클래스로 s1 데이터 생성
s1 = pd.Series(data)
# s1
print(s1)
print(type(s1))

# Series 속성
print(s1.index)
print(s1.values)
print(s1.shape) # 튜플

# 요소 선택(검색)
print(s1[0])
print(s1[1])
print(s1[2])
```

데이터 분석

- **DataFrame(데이터프레임)**

```
import pandas as pd(별칭)

pd.DataFrame(데이터, 인덱스)
```

속성	기능
index	- 데이터프레임의 인덱스 (생략하면 기본 0, 1, 2)
columns	- 데이터프레임의 칼럼
shape	- 데이터프레임의 크기 (행, 열)

데이터 분석

- **DataFrame(데이터프레임)**

```
import pandas as pd

df = pd.DataFrame({
    "name": ['키보드', '마우스', 'USB 메모리'],
    "price": [20000, 32000, 11000]
})

df
df.columns #['name', 'price']
df.shape  #(3, 2)
```

데이터 분석

- **DataFrame(데이터프레임)**

```
# 칼럼 추가
df['spec'] = ['유선', '무선', 'USB 메모리']
df

# 칼럼명 변경 - rename()
df = df.rename(columns={
    "name": "제품명",
    "price": "가격",
    "spec": "제품상세"
    })
df
```

	제품명	가격	제품상세
0	키보드	20000	유선
1	마우스	32000	무선
2	USB 메모리	11000	USB 메모리

데이터 분석

- **제미나이에게 csv 질문하기**

csv 파일에 대해 설명해 주세요

+ Gemini 2.5 Flash

Gemini

csv 파일에 대해 설명해 주세요

CSV(Comma Separated Values) 파일은 데이터를 쉼표로 구분하여 저장하는 텍스트 파일 형식입니다. 스프레드시트나 데이터베이스에서 데이터를 저장하고 교환할 때 널리 사용됩니다. 각 줄은 데이터베이스 테이블의 한 행을 나타내고, 각 줄의 쉼표는 해당 행의 다른 필드를 구분합니다. CSV 파일은 일반 텍스트 파일이므로 어떤 텍스트 편집기로든 열 수 있고, 다양한 프로그램에서 쉽게 가져오거나 내보낼 수 있다는 장점이 있습니다.

데이터 분석

- **데이터 프레임을 CSV 파일로 변환**

  CSV(Comma Seperated Value) 파일: 쉼표(,)로 데이터를 구분하여 저장하는 텍스트 파일 형식이다. 주로 표형태의 데이터를 저장하는 데 사용하며 엑셀에서 쉽고 열고 편집할 수 있음

☞ CSV 파일로 변환

df.to_csv("computer.csv", index=False)

☞ CSV 파일 읽기

pd.read_csv("computer.csv")

데이터 분석

- **CSV 파일로 변환 및 CSV 읽기**

```
# csv 파일 만들기
df.to_csv("/content/drive/MyDrive/데이터분석/computer.csv", index=False)

# csv 파일 읽기
computer = pd.read_csv("/content/drive/MyDrive/데이터분석/computer.csv")
computer
```

	제품명	가격	제품상세
0	키보드	20000	유선
1	마우스	32000	무선
2	USB 메모리	11000	USB 메모리

구글 코렙

❖ 드라이브 마운트

- 폴더 > 드라이브 마운트 > 드라이브 연결

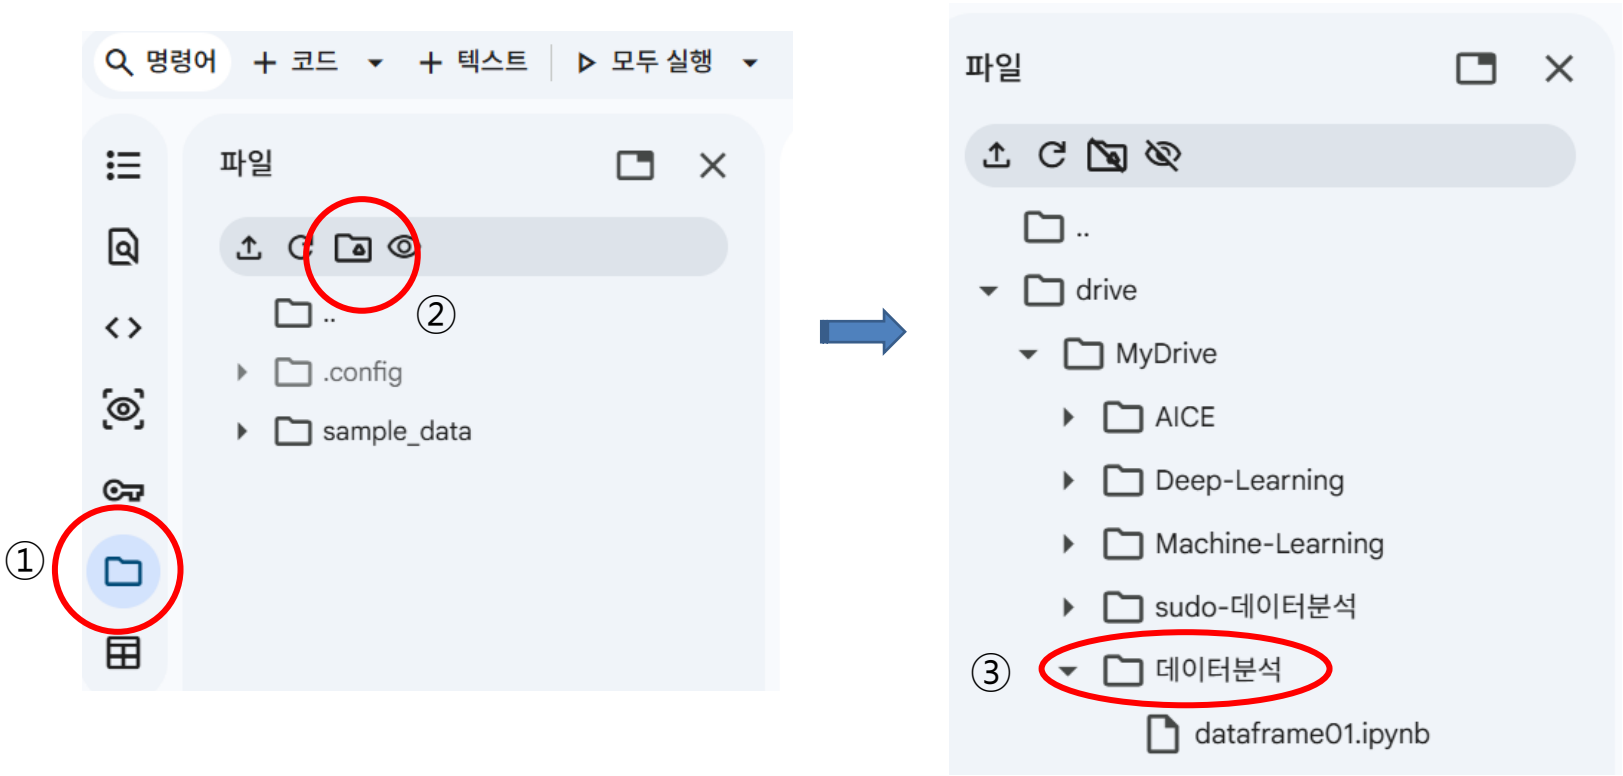

구글 코렙

❖ 훈련 데이터 업로드

- (...) 메뉴 > 경로 복사

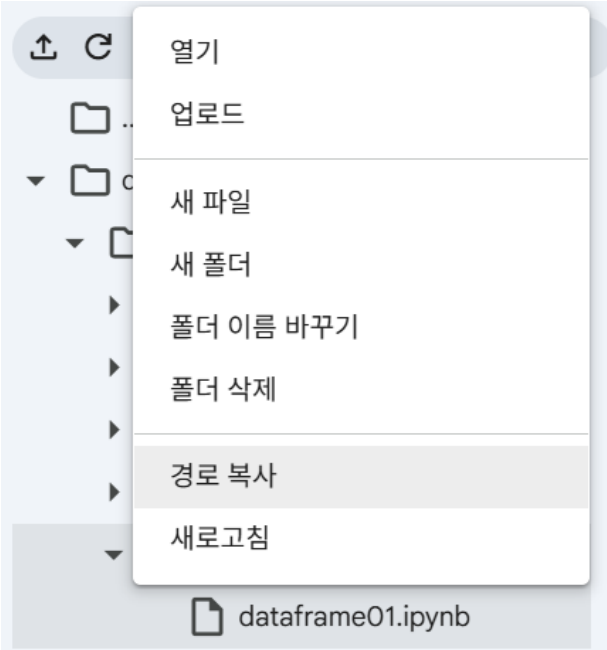

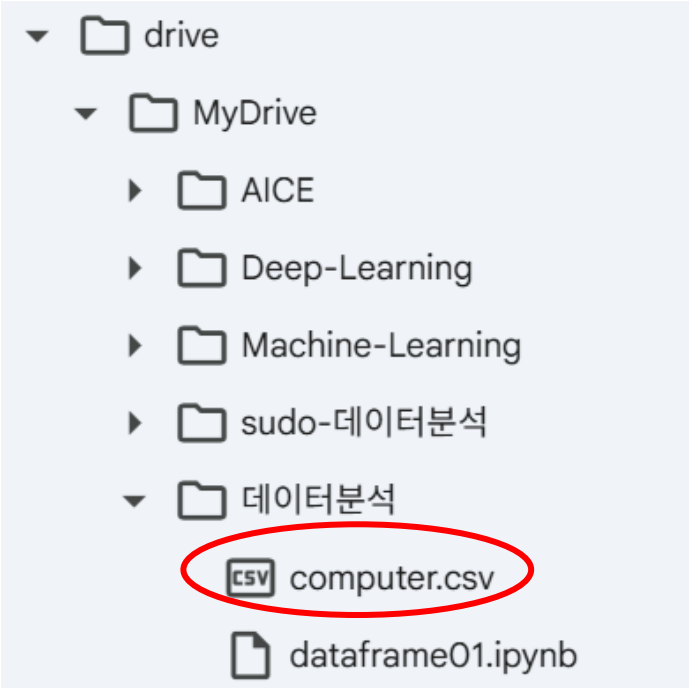

데이터 관리

- **행과 열 선택**

속성	범위	예시
loc[인덱스명, 칼럼명] (location)	끝 인덱스 포함	인덱스 - 라벨인덱스
iloc[인덱스번호, 칼럼번호] (integer location)	끝 인덱스 - 1	인덱스 – 순서(0부터 시작)

데이터 관리

- **행/열 선택 : loc[행이름, 열이름] 사용**

```
# 행 선택 - loc[행(행 이름)]
df.loc[0:1] #0행, 1행 출력

# 특정 요소 선택 - loc[행 이름, 열 이름]
print(df.loc[0, "제품명"]) # 키보드
print(df.loc[1, "가격"]) # 32000
print(df.loc[0:1, "제품명"])
print(df.loc[0:1, ["제품명", "가격"]])
```

```
키보드
32000
0    키보드
1    마우스
Name: 제품명, dtype: object
   제품명     가격
0  키보드  20000
1  마우스  32000
```

데이터 관리

- **행/열 선택 : iloc[행번호, 열번호] 사용**

```
# 행 선택 - iloc[행(인덱스)]
df.iloc[0:1] #0행만 출력(첫인덱스: 끝인덱스-1)

# 특정 요소 선택 - iloc[행 인덱스, 열 인덱스]
print(df.iloc[0, 0]) # 키보드
print(df.iloc[1, 1]) # 32000
print(df.iloc[0:2, 0])
print(df.iloc[0:2, [0, 1]])
```

```
키보드
32000
0    키보드
1    마우스
Name: 제품명, dtype: object
   제품명     가격
0  키보드  20000
1  마우스  32000
```

데이터 관리

- 데이터 프레임 - 요소값 변경(업데이트)

df.loc[행이름, 열이름] = “변경할 값 "

df.iloc[행번호, 열번호] = “변경할 값 "

- 데이터 프레임 - 요소값 추가

df[열] = “추가할 칼럼“ => 열 추가

df.loc[행] = “추가할 값“ => 행 추가

데이터 관리

- **행/열 요소 변경 및 추가**

```
# 요소값 변경 및 추가
df2 = df.copy() # 원본 복사
df2

# '무선마우스'의 가격을 27000원으로 변경
df2.loc[1, "가격"] = 27000

# 행 추가
df2.loc[3] = ["키보드", 30000, "무선"]
df2

# 열 추가 - '할인가' (가격 * 10%)
df2["할인가"] = df2['가격'] * 0.1
df2
```

	제품명	가격	제품상세	할인가
0	키보드	20000	유선	2000.0
1	마우스	27000	무선	2700.0
2	USB 메모리	11000	USB 메모리	1100.0
3	키보드	30000	무선	3000.0

데이터 관리

- **행/열 삭제**

df.drop(행, axis=0) => 행 삭제

df.drop(열, axis=1) => 열 삭제

```
# 행, 열 삭제
df3 = df2.copy()
df3

# 3행 삭제
df3 = df3.drop(3, axis=0)

# '할인가' 열 삭제
df3 = df3.drop("할인가", axis=1)
df3
```

데이터 탐색

- **데이터 탐색을 위한 주요 함수**

```
# 데이터 정보
df2.info()

# 데이터 출력 - 기본 5개
df2.head(2)

# 통계 요약 - 기본 숫자형 칼럼
df2.describe()
df2.describe(include='number')

# 문자형 칼럼 요약
df2.describe(include='object')

# 고유값의 개수
df2["제품명"].value_counts()
```

데이터 탐색

- **데이터 탐색을 위한 주요 함수**

```
<class 'pandas.core.frame.DataFrame'>
Index: 4 entries, 0 to 3
Data columns (total 4 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   제품명      4 non-null      object
 1   가격       4 non-null      int64
 2   제품상세     4 non-null      object
 3   할인가      4 non-null      float64
dtypes: float64(1), int64(1)
memory usage: 332.0+ bytes
```

	가격	할인가
count	4.000000	4.000000
mean	22000.000000	2200.000000
std	8445.906306	844.590631
min	11000.000000	1100.000000
25%	17750.000000	1775.000000
50%	23500.000000	2350.000000
75%	27750.000000	2775.000000
max	30000.000000	3000.000000

제품명	count
키보드	2
마우스	1
USB 메모리	1

데이터 전처리

- **결측치 삭제 및 대체**

함수	설명
drop(행, axis=0) drop(열, axis=1)	NaN이 포함된 행 삭제 NaN이 포함된 열 삭제
dropna()	NaN이 포함된 모든 행 삭제
fillna()	- 수치형: 평균(mean()), 중간값(median()) - 문자형: 빈도값(mode())
isnull() isnull().sum()	- 결측치 확인(True / False로 반환) - 결측치 개수(True(1))

데이터 전처리

- **결측치 대체**

```
import pandas as pd

data = {
    "메뉴": ["김밥", "비빔밥", "자장면", "우동", None, "자장면", "김밥"],
    "가격": [3000, 7000, 5500, None, 3500, 6000, 4000],
    "분류": ["한식", "한식", "중식", "일식", "한식", "중식", "한식"]
}

food = pd.DataFrame(data)
food

# 데이터 탐색
food.info()
food.describe()
food.head()
```

데이터 전처리

- **결측치 대체**

```
# csv 파일 만들기
food.to_csv("/content/drive/MyDrive/데이터분석/food.csv", index=False)
```

```
# csv 파일 읽기
df = pd.read_csv("/content/drive/MyDrive/데이터분석/food.csv")
df
```

	메뉴	가격	분류
0	김밥	3000.0	한식
1	비빔밥	7000.0	한식
2	자장면	5500.0	중식
3	우동	NaN	일식
4	NaN	3500.0	한식
5	자장면	6000.0	중식
6	김밥	4000.0	한식

데이터 전처리

- **결측치 대체**

```
# 결측치 확인
df.isna().sum() #df.isnull().sum() 도 가능

# 결측치 대체 - 수치형(중간값)
median = df["가격"].median()
median #4750.0

# inplace=True, 즉시 변경
df["가격"].fillna(median, inplace=True)
df

# 결측치 확인
df.isnull().sum()
```

	0
메뉴	1
가격	0
분류	0

데이터 전처리

- **결측치 대체**

```
# 문자형(최빈값)
freq = df["메뉴"].mode()[0]
freq #김밥

df['메뉴'].fillna(freq, inplace=True)
df

# 결측치 확인
df.isnull().sum()
```

	0
메뉴	0
가격	0
분류	0

데이터 시각화

- **matplotlib 라이브러리**

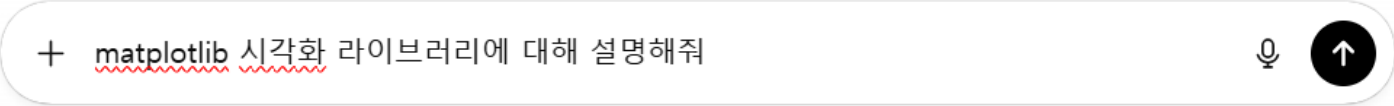

- 데이터 분석, 과학 시각화, 보고서 작성 등 다양한 분야에서 그래프를 그릴 때 사용됩니다.
- 주요 그래프 종류

종류	함수명	예시
선 그래프	plot()	plt.plot(x, y)
막대 그래프(수직/수직)	bar() / barh()	plt.bar(x, y) / plt.barh(x, y)
산점도	scatter()	plt.scatter(x, y)
히스토그램	hist()	plt.hist(data)
파이차트	pie()	plt.pie(data)

41

데이터 시각화

- 선 그래프

```
import matplotlib.pyplot as plt

# 데이터 준비
x = [1, 2, 3, 4, 5]
y = [2, 3, 5, 7, 11]

# 선 그래프
plt.plot(x, y, label='Prime numbers', color='blue', marker='o')
plt.title('Line Graph')
# plt.show()
```

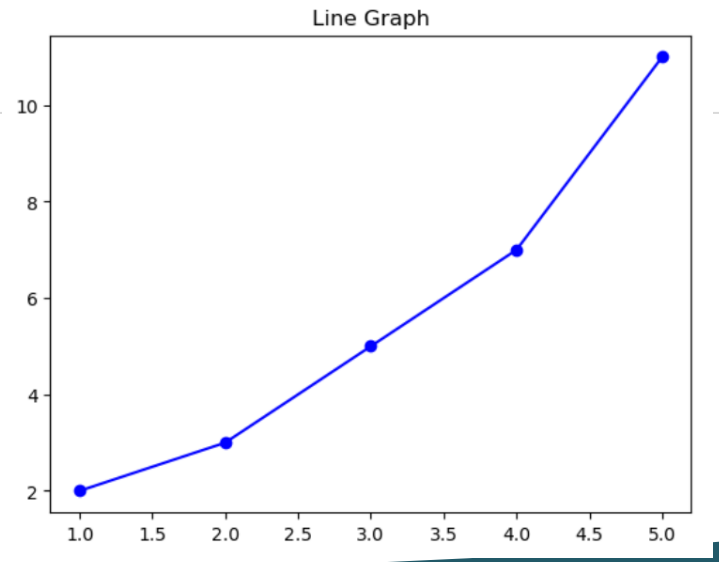

42

데이터 시각화

- 막대 그래프

```
import matplotlib.pyplot as plt

# 데이터 준비
fruits = ['apple', 'banana', 'grape', 'orange']
counts = [10, 15, 7, 12]
colors = ['red', 'yellow', 'purple', 'orange']

# 막대 그래프
plt.bar(fruits, counts, color=colors)
plt.title('과일 수량')
plt.xlabel('과일')
plt.ylabel('수량')

# plt.show()
```

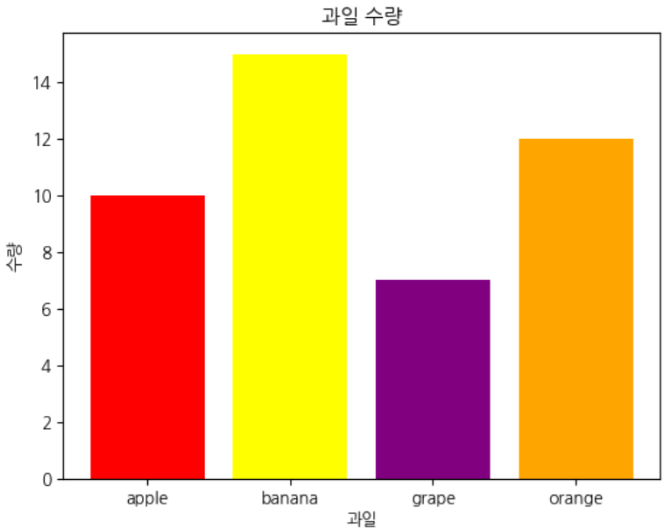

43

데이터 시각화

- 막대 그래프

막대 그래프의 제목을 한글로 표시해 주세요

+ Gemini 2.5 Flash

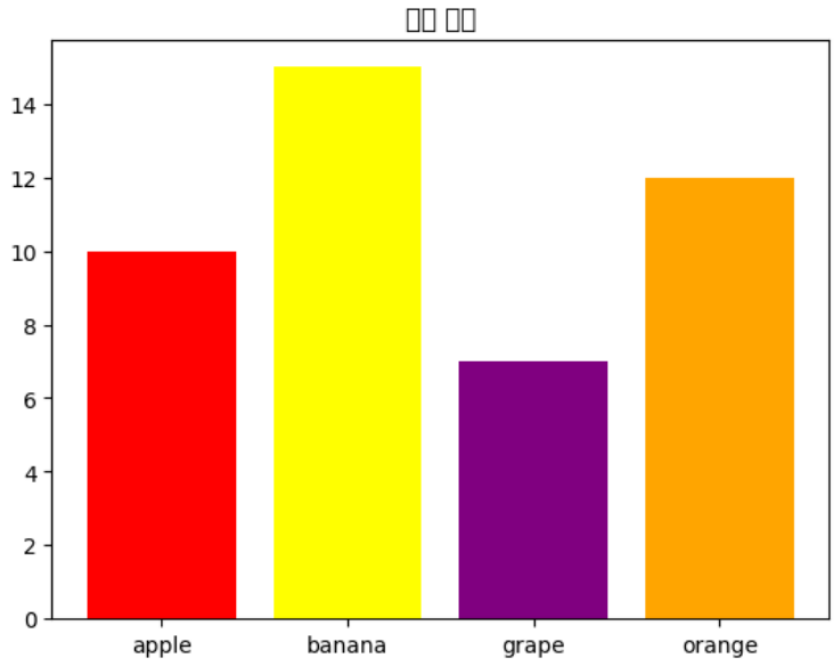

44

데이터 시각화

- 막대 그래프

```
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm

# Install Korean font (NanumGothic)
!sudo apt-get install -y fonts-nanum
!sudo fc-cache -fv

# Set font path and configure matplotlib
font_path = '/usr/share/fonts/truetype/nanum/NanumGothic.ttf'
fm.fontManager.addfont(font_path)
plt.rc('font', family='NanumGothic')
plt.rcParams['axes.unicode_minus'] = False
```


45

데이터 시각화

- 산점도 그래프

```
# 데이터 준비
height = [160, 170, 175, 165, 172, 168, 174, 178, 185, 166]
weight = [50, 70, 65, 60, 77, 55, 70, 75, 90, 63]

# 산점도 그래프
plt.scatter(height, weight)
plt.title('키와 몸무게')
plt.xlabel('키')
plt.ylabel('몸무게')
```

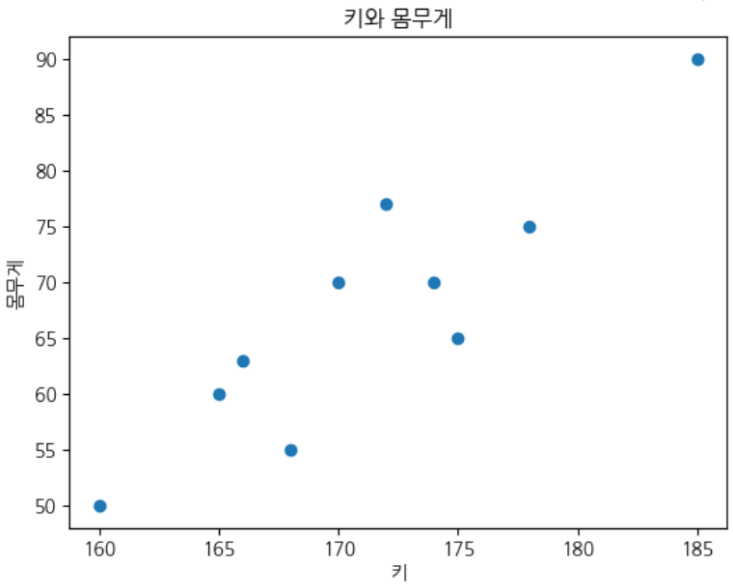

46

상관 분석 VS 회귀 분석

- **상관 분석 vs 회귀 분석**

상관 분석	회귀 분석
x와 y의 관련 정도를 확인	x가 y에 주는 영향을 추정하여 결과를 예측할 수 있음
산포도, 상관 계수	회귀식
광고비와 매출은 양의 상관관계가 있다.	광고비를 1% 늘리면 매출이 5% 증가할 것이다.

47

데이터 시각화

- **seaborn 라이브러리**
  - Python의 데이터 시각화 라이브러리로, 통계적 그래프를 쉽게 그릴 수 있도록 matplotlib을 기반으로 만들어졌다
  - pandas의 DataFrame과 잘 통합되어 있어, 데이터를 시각적으로 분석하고자 할 때 매우 유용하다

- **설치 방법**

  pip install seaborn

48

상관 분석 vs 회귀 분석

- **데이터 준비 및 탐색**

```python
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

df = sns.load_dataset('car_crashes')
df.head()

df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 51 entries, 0 to 50
Data columns (total 8 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   total           51 non-null     float64
 1   speeding        51 non-null     float64
 2   alcohol         51 non-null     float64
 3   not_distracted  51 non-null     float64
 4   no_previous     51 non-null     float64
 5   ins_premium     51 non-null     float64
 6   ins_losses      51 non-null     float64
 7   abbrev          51 non-null     object
dtypes: float64(7), object(1)
memory usage: 3.3+ KB
```


49

상관 분석 vs 회귀 분석

- **데이터 준비 및 탐색**

칼럼의 의미에 대해 알려주세요

+ Gemini 2.5 Flash

변수	의미
total	10만 명당 총 사고 건수
speeding	과속 관련 사고 비율
alcohol	음주 관련 사고 비율
not_distracted	비산만 상태 사고 비율
no_previous	이전 사고 기록 없음 비율
ins_premium	보험료
ins_losses	보험 손실 비용
abbrev	주 약자 (문자형 → 상관분석 제외됨)

50

상관 분석 vs 회귀 분석

- **상관 계수 및 시각화**

```
# 상관 계수
# corr = df.select_dtypes(include=['number']).corr()
corr = df.select_dtypes(exclude=['object']).corr()
corr

# 시각화 - 히트맵
sns.heatmap(corr, annot=True, cmap='coolwarm')
plt.title('Car Crash')
plt.xticks(rotation=45)
```

```
(array([0.5, 1.5, 2.5, 3.5, 4.5, 5.5, 6.5]),
 [Text(0.5, 0, 'total'),
  Text(1.5, 0, 'speeding'),
  Text(2.5, 0, 'alcohol'),
  Text(3.5, 0, 'not_distracted'),
  Text(4.5, 0, 'no_previous'),
  Text(5.5, 0, 'ins_premium'),
  Text(6.5, 0, 'ins_losses')])
```


51

상관 분석 vs 회귀 분석

- 상관 계수 및 시각화

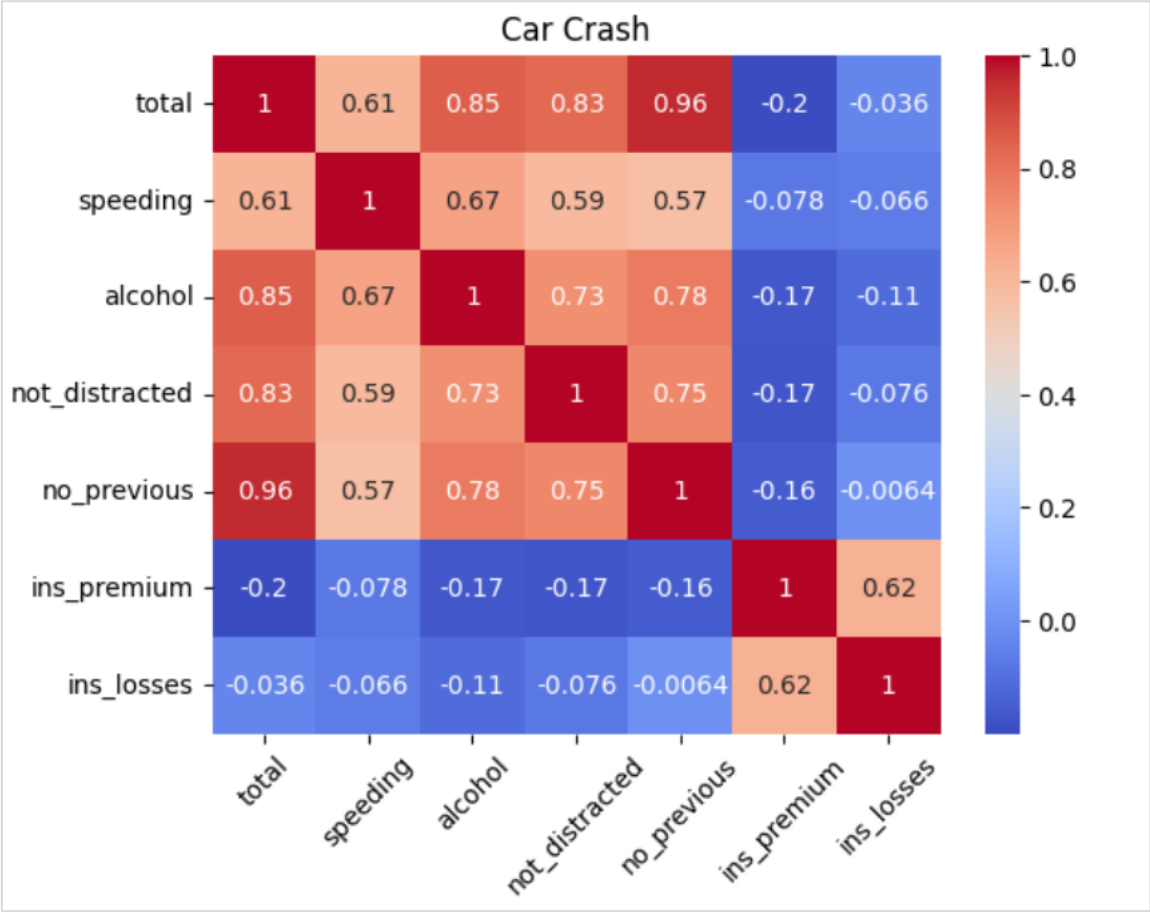

52

상관 분석 vs 회귀 분석

- **주요 상관 관계 분석**

상관 관계 분석을 해주세요.
한글로 번역해 주세요

+ Gemini 2.5 Flash

53

상관 분석 vs 회귀 분석

- **주요 상관 관계 분석**

✅ **① total ↔ speeding**

- **강한 양의 상관관계**
- 총 사고 건수가 많을수록 과속 관련 사고도 많음
- 📌 해석: 과속이 전체 사고 증가에 큰 영향을 미칠 가능성

✅ **② total ↔ alcohol**

- **양의 상관관계**
- 음주 사고 비율이 높은 주는 전체 사고율도 높은 경향
- 📌 해석: 음주 역시 사고의 주요 요인

✅ **③ speeding ↔ alcohol**

- 보통 **중간 정도의 양의 상관관계**
- 과속과 음주가 동시에 나타나는 경향

👉 즉, 위험 운전 행동들이 함께 발생하는 경향이 있음

✅ **④ ins_premium ↔ ins_losses**

- **매우 강한 양의 상관관계**
- 보험 손실이 높을수록 보험료도 높음
- 📌 매우 자연스러운 결과 (보험사는 손실 반영)

54

타이타닉호 사례 분석

- 타이타닉호 데이터 준비

```python
import seaborn as sns

df = sns.load_dataset('titanic')
df.head()
```

	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive
0	0	3	male	22.0	1	0	7.2500	S	Third	man	True	NaN	Southampton	no
1	1	1	female	38.0	1	0	71.2833	C	First	woman	False	C	Cherbourg	yes
2	1	3	female	26.0	0	0	7.9250	S	Third	woman	False	NaN	Southampton	yes
3	1	1	female	35.0	1	0	53.1000	S	First	woman	False	C	Southampton	yes
4	0	3	male	35.0	0	0	8.0500	S	Third	man	True	NaN	Southampton	no

55

타이타닉호 사례 분석

- 타이타닉호 데이터 정보(결측치 확인)

#	Column	Non-Null Count	Dtype
0	survived	891 non-null	int64
1	pclass	891 non-null	int64
2	sex	891 non-null	object
3	age	714 non-null	float64
4	sibsp	891 non-null	int64
5	parch	891 non-null	int64
6	fare	891 non-null	float64
7	embarked	889 non-null	object
8	class	891 non-null	category
9	who	891 non-null	object
10	adult_male	891 non-null	bool
11	deck	203 non-null	category
12	embark_town	891 non-null	object
13	alive	891 non-null	object
14	alone	891 non-null	bool

#	Column	Non-Null Count	Dtype
0	survived	891 non-null	int64
1	pclass	891 non-null	int64
2	sex	891 non-null	object
3	age	714 non-null	float64
4	sibsp	891 non-null	int64
5	parch	891 non-null	int64
6	fare	891 non-null	float64
7	embarked	889 non-null	object
8	class	891 non-null	category
9	who	891 non-null	object
10	adult_male	891 non-null	bool
11	embark_town	891 non-null	object
12	alive	891 non-null	object
13	alone	891 non-null	bool

56

타이타닉호 사례 분석

- **타이타닉호 데이터 분석 및 처리**

```python
# 결측치 처리
# df.isnull().sum()
print(df.isna().sum())

# age, embarked, embark_town 칼럼 - 결측치 대체
# deck 칼럼 - 결측치 삭제
df2 = df.copy() #원본 복사

# age - 평균값 계산
mean_age = df2['age'].mean()
print(mean_age) #29.699

# 평균값으로 채우기
df2['age'] = df2['age'].fillna(mean_age)

# embarked - 최빈값 계산
most_freq = df2['embarked'].mode()[0]
print(most_freq) #S

df2['embarked'] = df2['embarked'].fillna(most_freq)
print(df2.isna().sum())
```

```
survived         0
pclass           0
sex              0
age              0
sibsp            0
parch            0
fare             0
embarked         0
class            0
who              0
adult_male       0
deck           688
embark_town      2
alive            0
alone            0
dtype: int64
```

타이타닉호 사례 분석

- 타이타닉호 데이터 분석 및 처리

```python
# embark_town - 최빈값 이용
print(df2['embark_town'][825:830])

most_freq = df2['embark_town'].mode()[0]
print(most_freq) #Southampton

# 최빈값으로 채우기
df['embark_town'] = df['embark_town'].fillna(most_freq)
print(df['embark_town'][825:830])

# deck열 삭제
df2 = df2.drop('deck', axis=1)
df2.info()
print(df2.isna().sum())
df2.columns # 칼럼 확인
```

```
survived       0
pclass         0
sex            0
age            0
sibsp          0
parch          0
fare           0
embarked       0
class          0
who            0
adult_male     0
embark_town    0
alive          0
alone          0
dtype: int64
```


58

타이타닉호 사례 분석

- 타이타닉호 - 성별에 따른 생존자 수 그래프

```
import seaborn as sns
import matplotlib.pyplot as plt

# 예제 데이터셋 로드
df = sns.load_dataset('titanic')

# 데이터 확인
print(df.head())

# 성별에 따른 생존자 수 시각화 (막대그래프)
sns.countplot(data=df, x='sex', hue='survived')
plt.title('성별에 따른 생존자 수')
plt.show()
```


59

타이타닉호 사례 분석

- 타이타닉호 - 성별에 따른 생존자 수 그래프

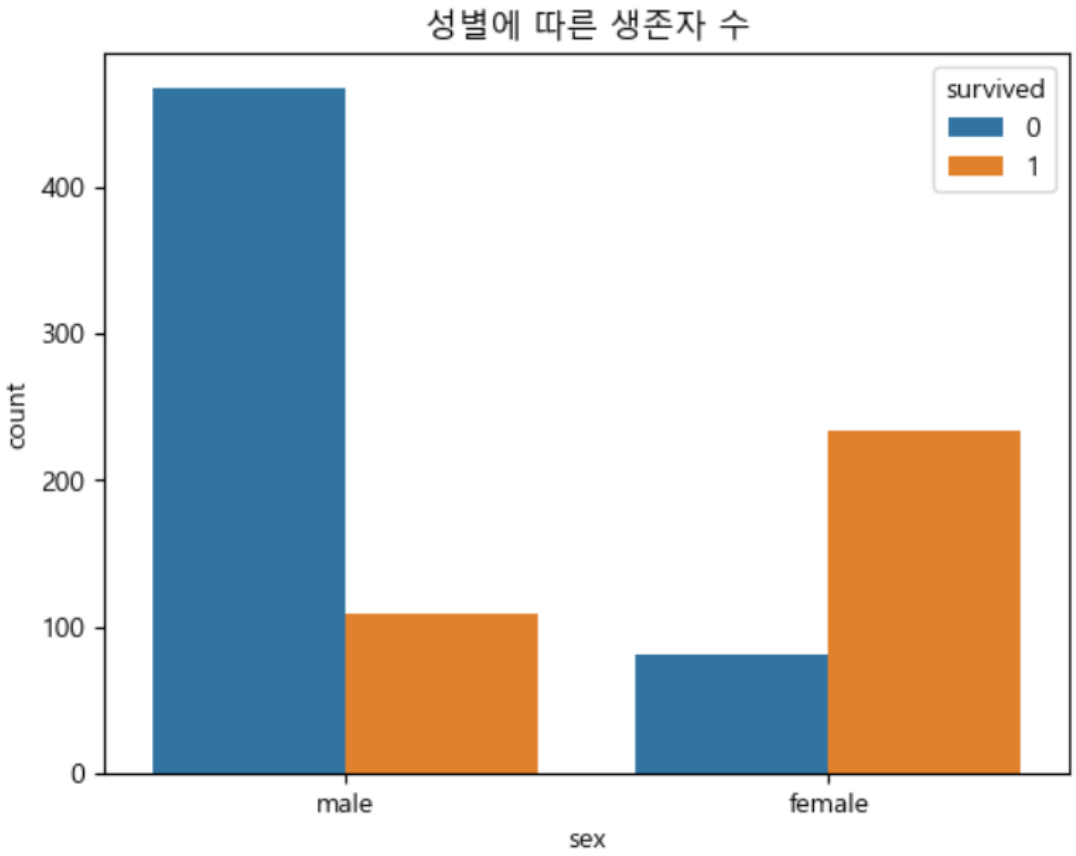

60

Numpy(넘파이)

- **Numpy(Numeric Python)**

  - **대규모 수치 계산과 배열 연산을 빠르게 처리**하기 위한 파이썬 라이브러리입니다.
  - 과학 계산, 데이터 분석, 머신러닝(딥러닝)에 주로 활용됩니다.

수학 관련 함수	설명
np.sum([1, 2, 3])	합계(리스트, 튜플)
np.mean([1, 2, 3])	평균(리스트, 튜플)
np.square(n)	n의 제곱수
np.sqrt(n)	n의 제곱근

Numpy(넘파이)

- **수학 관련 함수**

```
import numpy as np

# 수학 관련 함수
n1 = np.sum([1, 2, 3])  #합계
print(n1)
n2 = np.mean([1, 2, 3, 4]) #평균
print(n2)
n3 = np.square(9) #제곱수
print(n3)
n4 = np.sqrt(4) #제곱근
print(n4)
```

Numpy(넘파이)

- **Numpy(Numeric Python)**

배열 관련 함수	설명
np.array([1, 2, 3])	1차원 배열
np.array([[1, 2], [3,4]])	2차원 배열
np.arange(n)	1차원 배열로 0부터 n-1까지 생성
a.reshape(x, y)	1차원 배열(a)을 2차원 배열로 변환
b.flatten()	2차원 배열(b)을 1차원 배열로 변환
np.zeros()	0으로 만들어진 배열 생성
np.ones()	1로 만들어진 배열 생성

Numpy(넘파이)

- **Numpy(Numeric Python)**

```python
# 1차원 배열
x = np.array([1, 2, 3])
print(x)
print(type(x)) # 타입
print(x.shape) # 크기

# 인덱싱 및 슬라이싱
print(x[0])
print(x[2])
print(x[-1])
print(x[0:3])
print(x[:])
print(x[:-1])
```

```
[1 2 3]
(3,)
1
3
3
[1 2 3]
[1 2 3]
[1 2]
```

Numpy(넘파이)

- **Numpy(Numeric Python)**

```python
# 2차원 배열
d2 = np.array([
    [1, 2, 3],
    [4, 5, 6]
])
print(d2)
print(d2.shape)

# 인덱싱 및 슬라이싱
print(d2[0, 0])
print(d2[1, 1])
print(d2[0:, 0:])
print(d2[1:, 1:])
```

```
[[1 2 3]
 [4 5 6]]
(2, 3)
1
5
[[1 2 3]
 [4 5 6]]
[[5 6]]
```

Numpy(넘파이)

- **Numpy(Numeric Python)**

```python
# arange(시작값, 종료값, 증감값) - (종료값-1)
a = np.arange(10)
print(a)
b = np.arange(0, 10, 1)
print(b)
c = np.arange(0, 10, 2)
print(c)

# 1차원 배열을 2차원 배열
a2 = a.reshape(2,5)
print(a2)

# 2차원을 1차원 배열로
a3 = a2.flatten()
print(a3)
```

```
[0 1 2 3 4 5 6 7 8 9]
[0 1 2 3 4 5 6 7 8 9]
[0 2 4 6 8]
[[0 1 2 3 4]
 [5 6 7 8 9]]
[0 1 2 3 4 5 6 7 8 9]
```

Numpy(넘파이)

- **Numpy(Numeric Python)**

```python
# 결측치(nan)
a = np.nan
print(a)
print(type(a))

# 0 생성
a1 = np.zeros((3, 3))
print(a1)

# 1 생성
a2 = np.ones((2, 3))
print(a2)

a3 = np.ones((2, 3), dtype=int)
print(a3)
```

```
nan
<class 'float'>
[[0. 0. 0.]
 [0. 0. 0.]
 [0. 0. 0.]]
[[1. 1. 1.]
 [1. 1. 1.]]
[[1 1 1]
 [1 1 1]]
```

머신러닝(Machine Learning)

+ 머신러닝에 대해 설명해 줘

머신러닝이란? 명시적으로 규칙을 코딩하지 않아도, 데이터로부터 패턴을 학습해 예측·판단하는 인공지능 기술

머신러닝의 핵심 개념

1️⃣ **데이터**

- 학습의 재료
- 많고, 정확할수록 성능이 좋아짐

2️⃣ **모델(Model)**

- 데이터를 학습한 결과물
- 예: "이메일이 스팸일 확률은 92%"

3️⃣ **학습(Training)**

- 데이터를 보고 모델이 규칙을 조정하는 과정

4️⃣ **예측(Prediction)**

- 새로운 데이터에 대해 결과를 맞혀보는 것

머신러닝(Machine Learning)

❖ 지도 학습 vs 비지도 학습

	지도 학습	비지도학습
분석 모형 (알고리즘)	• 회귀 • 분류	• 군집 • 차원 축소
특징	• 정답(레이블)을 알고 있는 상태에서 학습 • 회귀 – 가격, 매출, 주가 예측 • 분류 – 고객분류, 질병 진단, 스팸 메일 필터링	• 정답(레이블)이 없는 상태에서 서로 비슷한 데이터를 찾아서 그룹화(클러스터링) • 구매 패턴 분석, 유투브 추천 등

머신러닝(Machine Learning)

❖ **지도 학습**

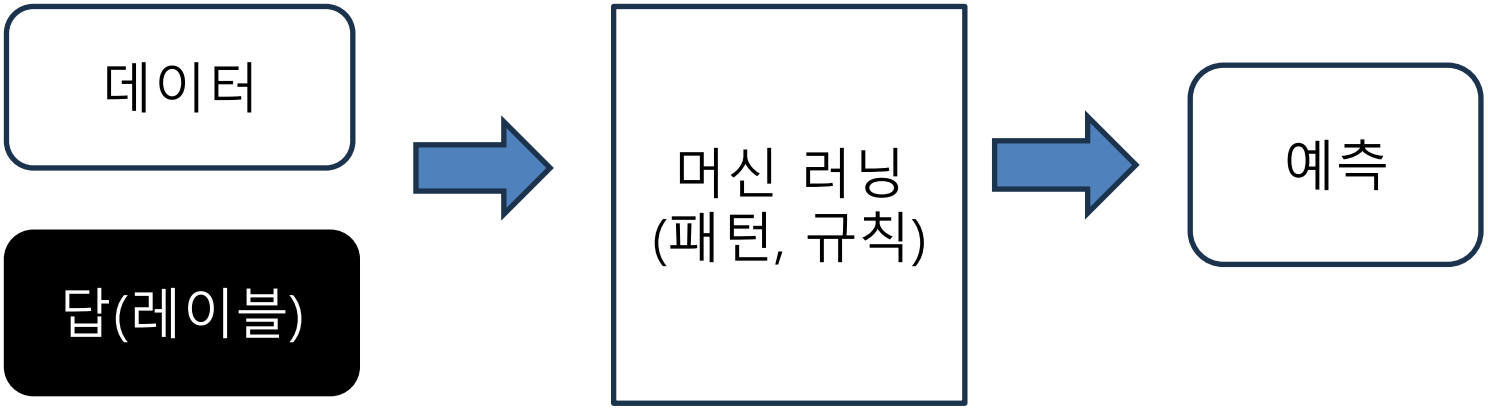

머신러닝(Machine Learning)

❖ **비지도 학습**

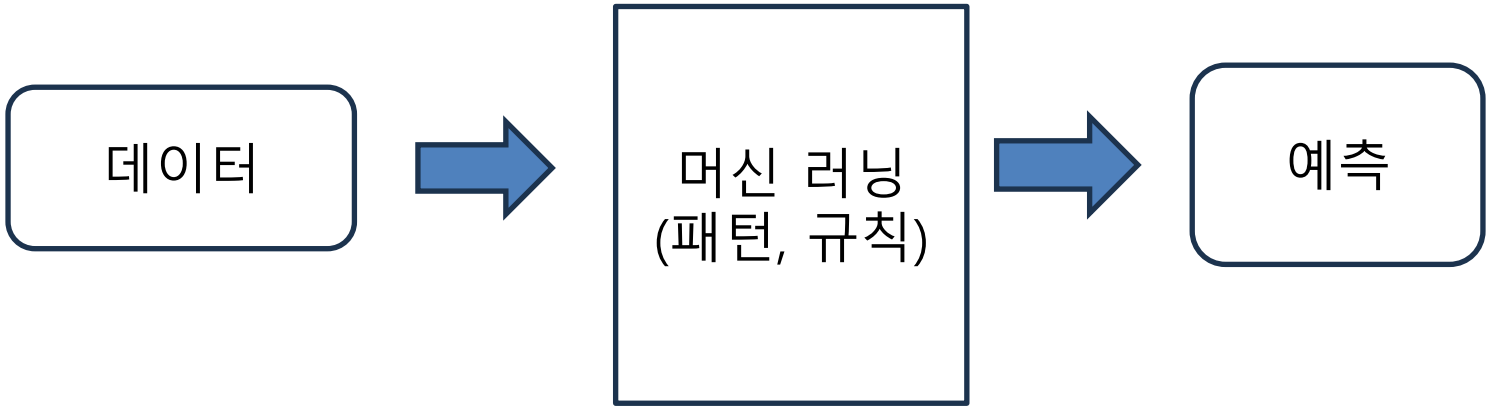

머신러닝(Machine Learning)

❖ 강화 학습

- 강화란 '어떤 것의 수준이나 정도를 높인다'는 의미로 인공지능의 수준을 높이는 것을 말한다.
- 에이전트가 환경과 상호작용하면서 보상 신호에 따라 최적의 정책을 찾아내는 방법

- 벽돌깨기 게임 – 딥마인드(구글) 회사
- 알파고(딥마인드) – 바둑을 학습한 인공지능
- 자율주행 자동차, 인공지능 로봇으로 확장되고 있음

회귀(Regression)

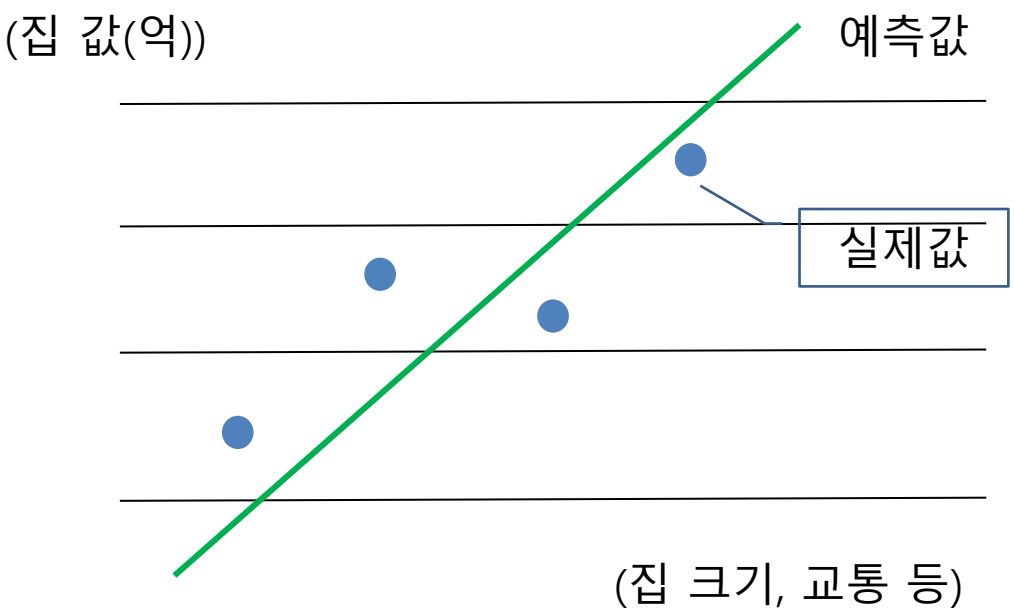

분류(Classification)

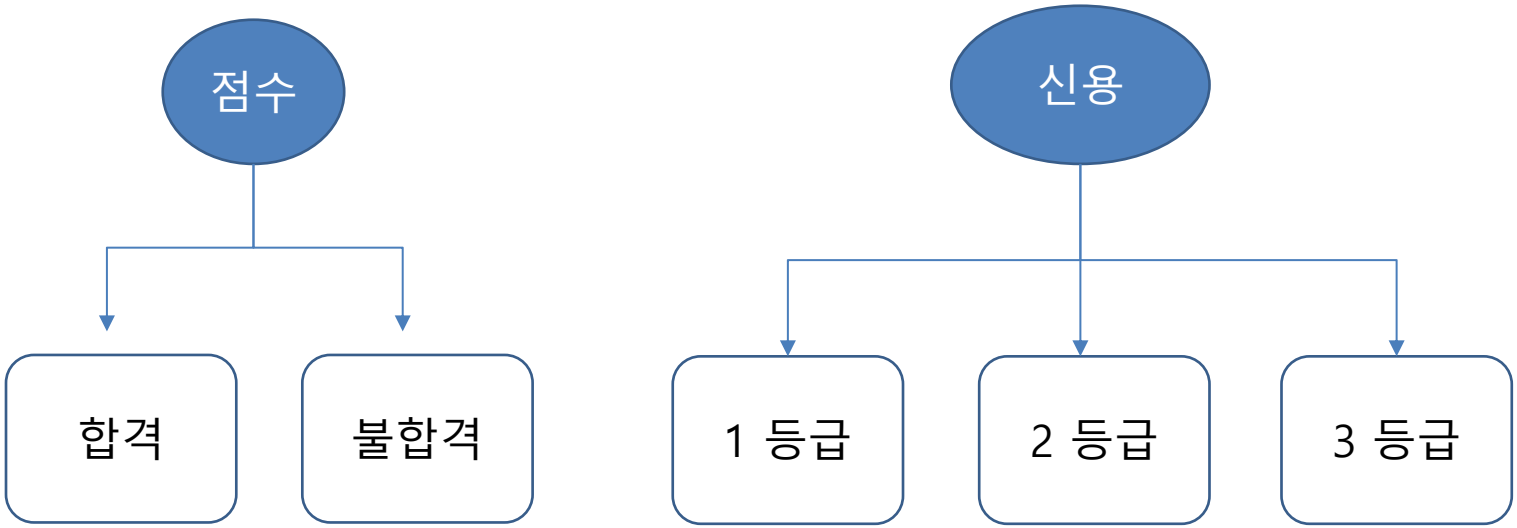

머신러닝 프로세스

- 머신러닝 모델 예측 프로세싱

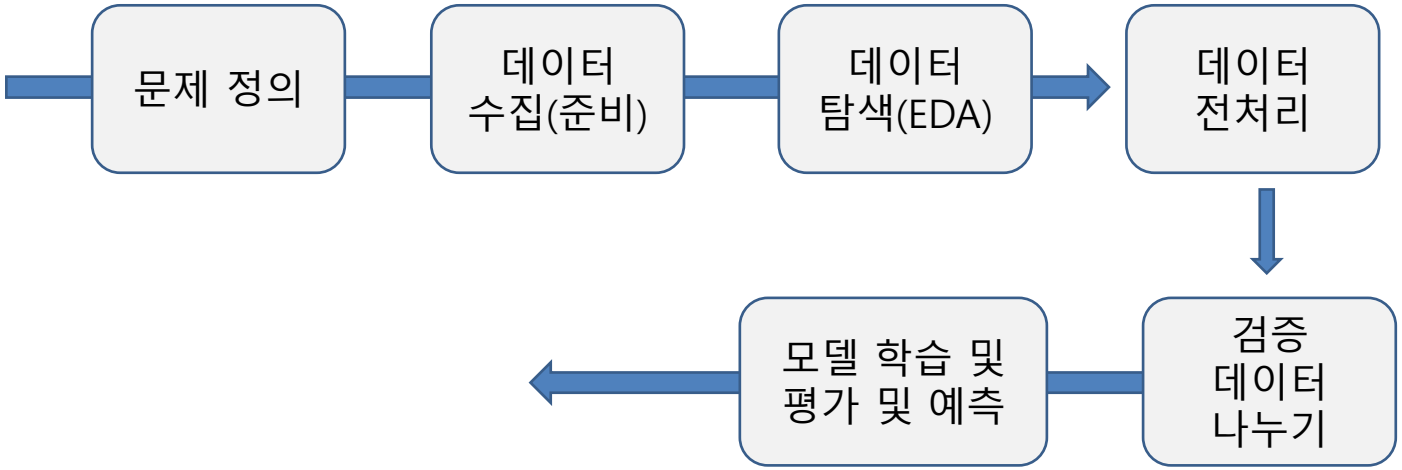

데이터 수집(준비)

- 데이터는 학습용과 검증으로 준비한다.
  - ✓ 훈련 : 검증 비율

    80 : 20 or 70 : 30

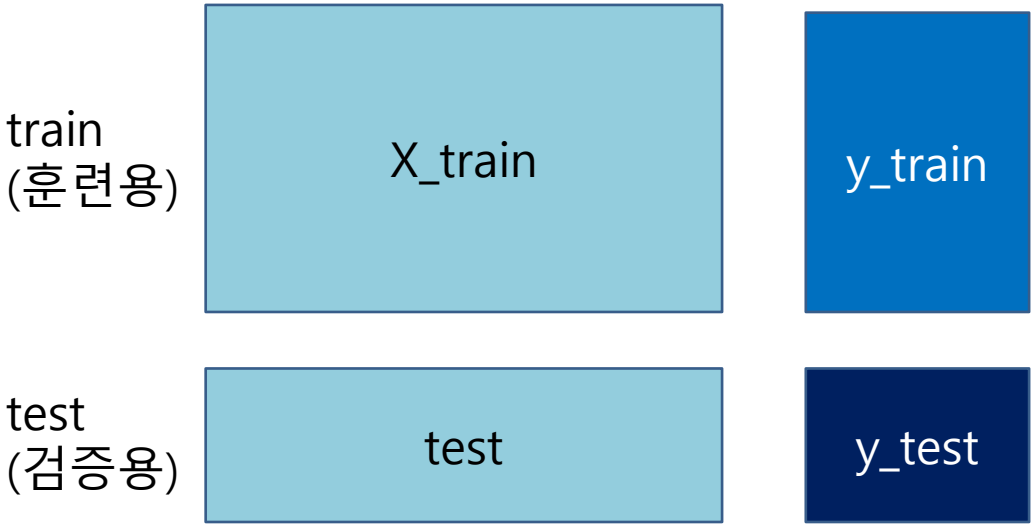

데이터 전처리

- 데이터 처리를 위한 모듈

	알고리즘	필수 여부
레이블 인코딩	sklearn.preprocessing(모듈) LabelEncoder	필수 (원-핫 인코딩중 선택)
스케일링	sklearn. preprocessing(모듈) StandardScaler	선택
데이터 분할	sklearn. model_selection(모듈) train_test_split	필수

데이터 전처리

- 인코딩(Encoding) – 문자형을 숫자형으로 변환
  - 레이블 인코딩(Label Encoding) : 각 칼럼을 숫자로 매핑하는 인코딩 방법이다.

train
(훈련용)

branch
A
B
C

test
(검증용)

branch
B
C
A

branch
0
1
2

branch
2
3
1

데이터 전처리

- 인코딩(Encoding) – 문자형을 숫자형으로 변환
  - 원-핫 인코딩(One-Hot Encoding) : 각 칼럼에 대해 새로운 칼럼을 만들고 새로운 칼럼에 0 또는 1이 저장된다.

train
(훈련용)

branch
A
B
C

test
(검증용)

branch
B
C
A

branch_A	branch_B	branch_C
1	0	0
0	1	0
0	0	1

branch_A	branch_B	branch_C
0	1	0
0	0	1
1	0	0

모델 학습 및 평가

- 모델 학습 및 평가

지도 학습	알고리즘	평가 지표
분류	sklearn.ensemble(모듈) RandomForestClassifier	sklearn.metrics(모듈) roc_auc_score, f1_score
회귀	sklearn.linear_model(모듈) LinearRegression sklearn.ensemble(모듈) RandomForestRegressor	sklearn.metrics(모듈) mean_squared_error mean_absolute_error

모델 학습 및 평가

- 모델 학습, 평가 및 예측

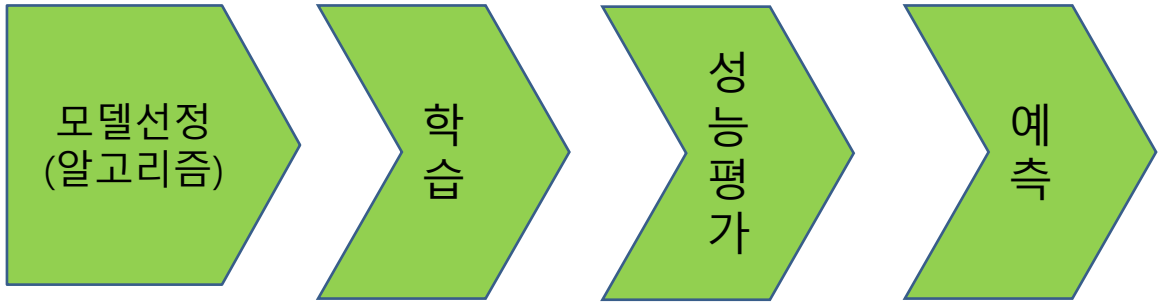

회귀(Regression)

❖ 선형 회귀

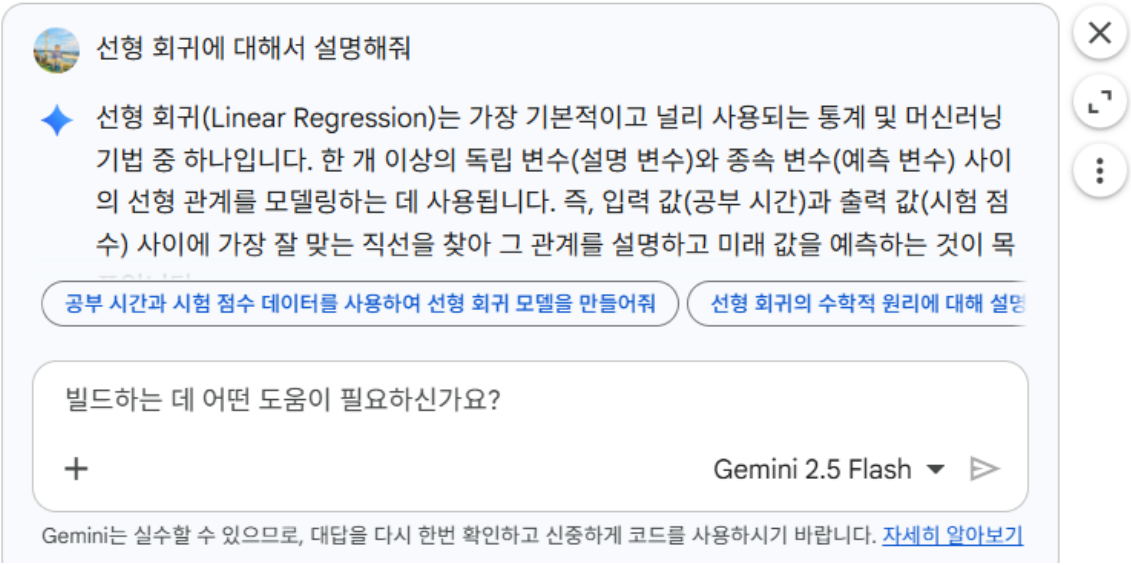

선형 회귀 분석

- **단순 선형 회귀**
  - $y=Wx+b$
  - W 를 가중치(Weight), b를 편향(bias)라고 부른다
  - 그래프의 형태는 **직선**

- **다중 선형 회귀**
  - $y=W_1x_1 + W_2x_2 + \ldots + W_nx_n + b$
  - 만약 2개의 독립 변수면 그래프는 **곡선**으로 나타남

선형 회귀 분석

- **공부한 시간의 차이에 따른 시험 성적 예측하기**
  - 성적을 변하게 하는 요소를 x라 하고 이 x값에 따라 변하는 '성적'을 y라 하자.
  - 독립 변수(x) : 공부한 시간, 사교육비 지출, 학생의 지능지수 등
  - 종속 변수(y) : 성적
  - 어떤 변수가 다른 변수에 영향을 준다면 두 변수 사이에 선형관계가 있다.

선형 회귀 분석

- **공부한 시간의 차이에 따른 시험 성적 예측하기**

공부 시간	2시간	4시간	6시간	8시간
성적	81점	93점	91점	97점

x = {2, 4, 6, 8}

y = {81, 93, 91, 97}

직선의 방정식을 구한다.

$y = ax + b$(일차함수)

기울기 a와 절편 b를 알아야 함

최소 제곱법

- **키의 차이에 따른 몸무게 예측하기**
  - 기울기 a 구하기

$$a = \frac{(x - x\text{평균})(y - y\text{평균})\text{의 합}}{(x - x\text{평균})^2\text{의 합}}$$

공부 시간(x) 평균 : (2 + 4 + 6 + 8) ÷ 4 = 5

성적(y) 평균: (81 + 93 + 91 + 97) ÷ 4 = 90.5

기울기 a = 2.3

X의 편차(각 값과 평균과의 차이)를 제곱해서 합한 값을 분모로 놓고,

x와 y의 편차를 곱해서 합한 값을 분자로 놓으면 기울기가 나옴

최소 제곱법

- **공부한 시간의 차이에 따른 시험 성적 예측하기**

  - 편차(deviation)

    관측값에서 평균을 뺀 값

  - 분산 (variance)

    편차(관측값-평균)를 제곱하고 그것을 모두 더한 후

    전체 개수로 나눈것. 즉 편차의 제곱의 평균을 말한다.

  - 표준편차(standard deviation)

    분산의 제곱근, 즉 분산 값에 루트를 씌운것을 말하며

    stdev라고 함.

최소 제곱법

- **공부한 시간의 차이에 따른 시험 성적 예측하기**
  - y절편 b값 구하기

b = y의 평균 – (기울기 a x (x의 평균))

b = 90.5 – (2.3 x 5) = 79

최적의 직선(방정식)

$y = 2.3x + 79$

공부 시간	2	4	6	8
성적	81	93	91	97
예측 값	83.6	88.2	92.8	97.4

최소 제곱법

- 공부한 시간의 차이에 따른 시험 성적 예측하기

공부 시간	2	4	6	8
성적	81	93	91	97
예측 값	83.6	88.2	92.8	97.4

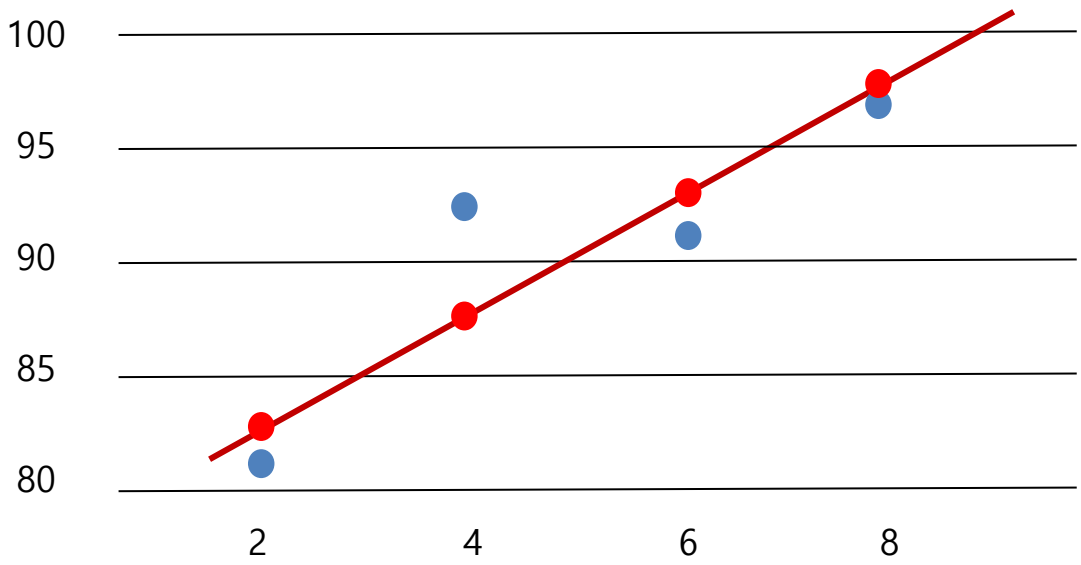

평균 제곱 오차

- **평균 제곱 오차**

  선형 회귀는 임의의 직선을 그어 이에 대한 평균 제곱 오차를 구하고, 이 값을 가장 작게 만들어주는 기울기(a)와 절편(b)을 찾아가는 작업이다.

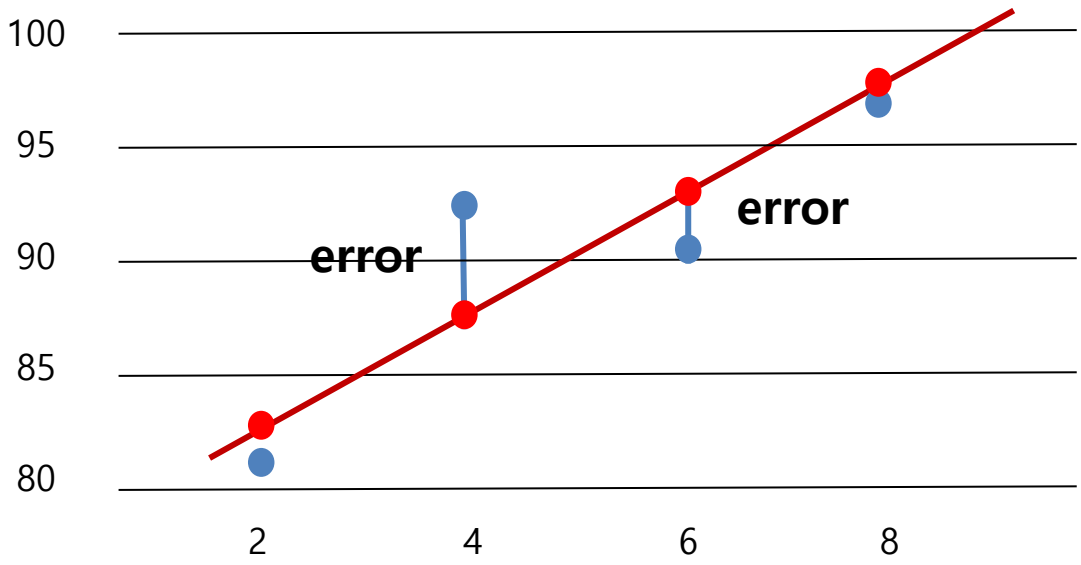

평균 제곱 오차

- **성능 평가 - 평균 제곱 오차 / 평균 절대값 오차**

  - MSE(Mean Squared Error)
    - 평균 제곱오차
    - 오차의 제곱을 평균으로 나눈 것

$$MSE = \frac{\sum_{i=1}^{n}(y-\hat{y})^2}{n}$$

  - MAE(Mean Absolute Error)
    - 평균 절대값 오차
    - 오차의 차이를 절대값으로 변환한 뒤 합산

$$MAE = \frac{\sum |y-\hat{y}|}{n}$$

평균 제곱 오차

- **오차 = 실제값 – 예측값**

공부 시간	2	4	6	8
성적	81	93	91	97
예측 값	82	88	94	100
오차	**1**	**-5**	**3**	**3**

분모 : 1 + 25 + 9 + 9 = 44

MSE = 44 / 4 = 11

MAE = 1+5+3+3 = 12

구글 코렙

❖ Google Colab 사용하기

Colaboratory는 **구글의 Jupyter Notebook 기반 클라우드 서비스**로, TPU나 GPU, CPU를 무료 제공하며 클라우드 IDE의 일부이다

- 계정 로그인 > 메뉴(선택) > **드라이브**

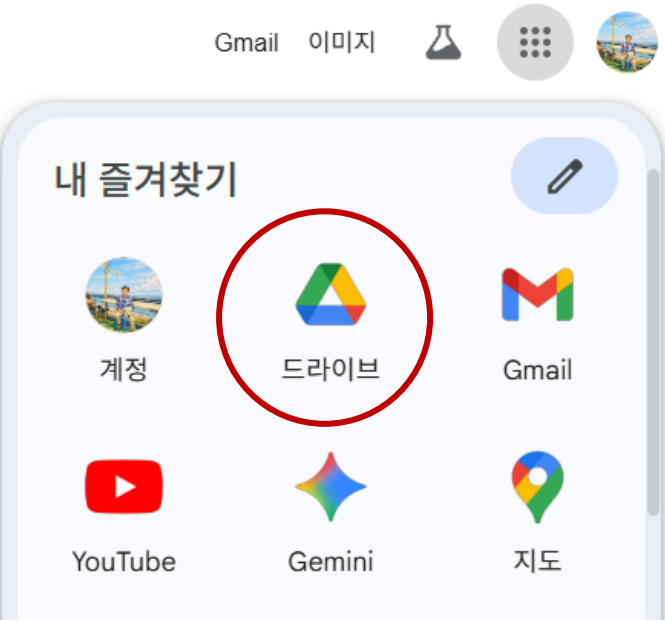

구글 코렙

❖ 리소스 사용 – 클라우드 컴퓨터 사용

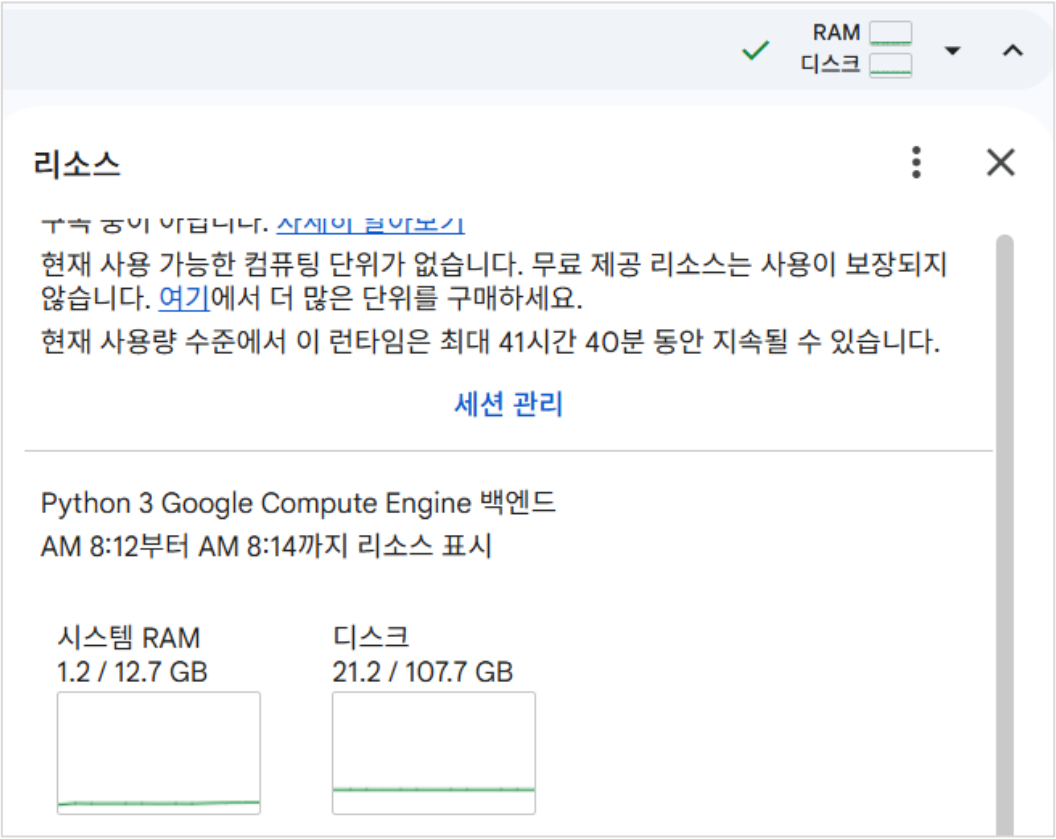

구글 코렙

❖ 구글 코랩(Colaboratory)

AI(Gemini) 지원 : 설정 > AI 지원 > 동의

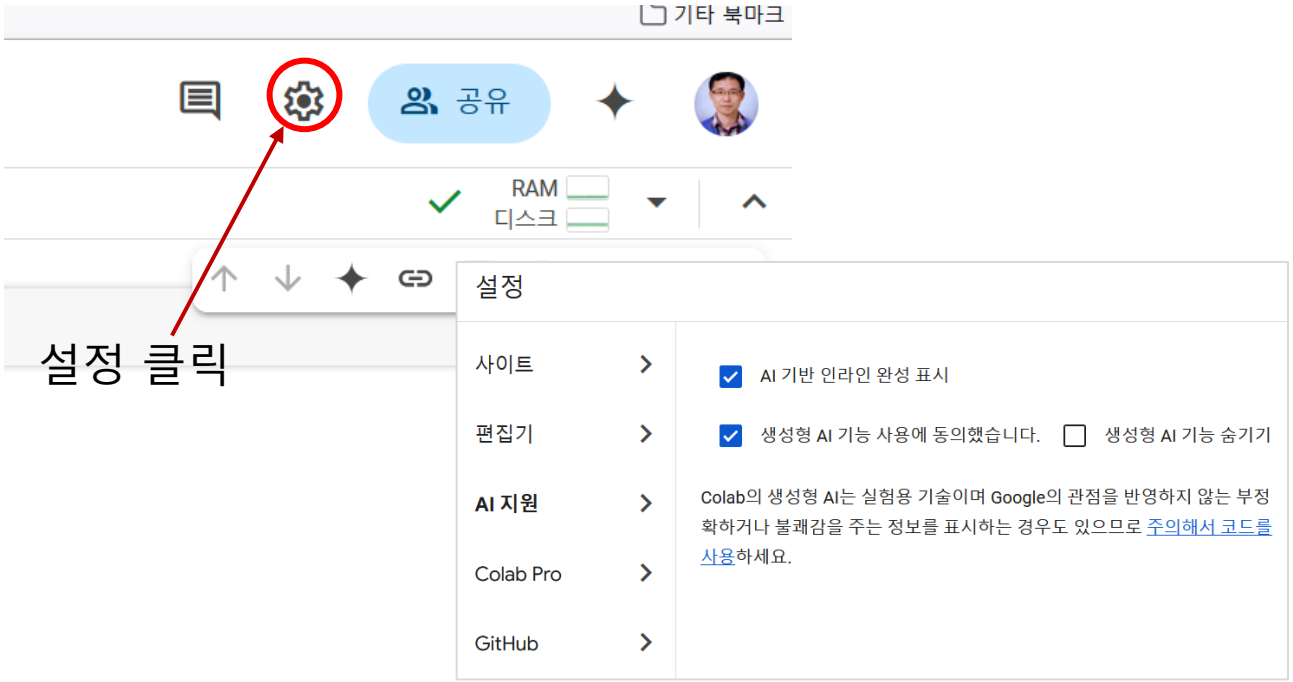

구글 코렙

❖ 새 노트 만들기

- 드라이브 > 홈
- + 신규 > 더보기 > Google Colaboratory

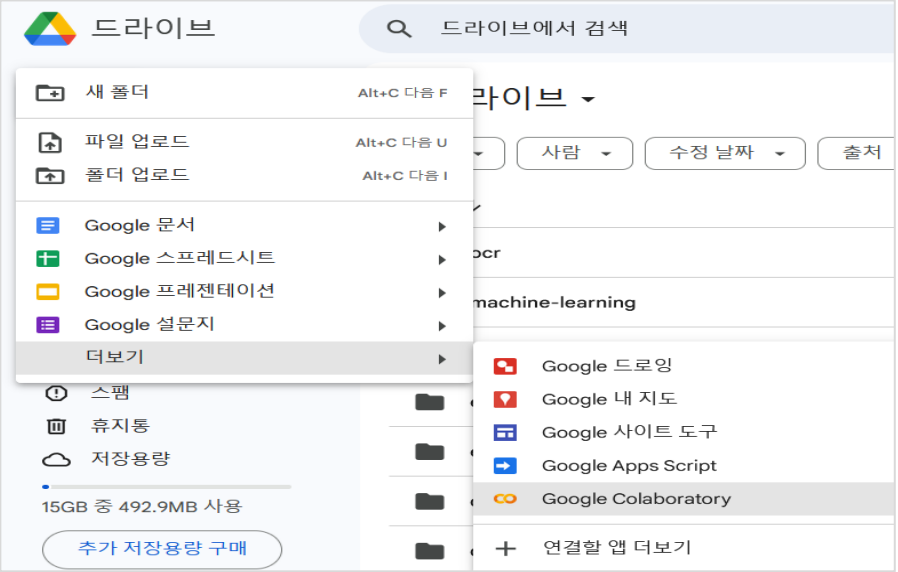

구글 코렙

❖ 새 노트 만들기

- 파일이름 > note01.ipynb

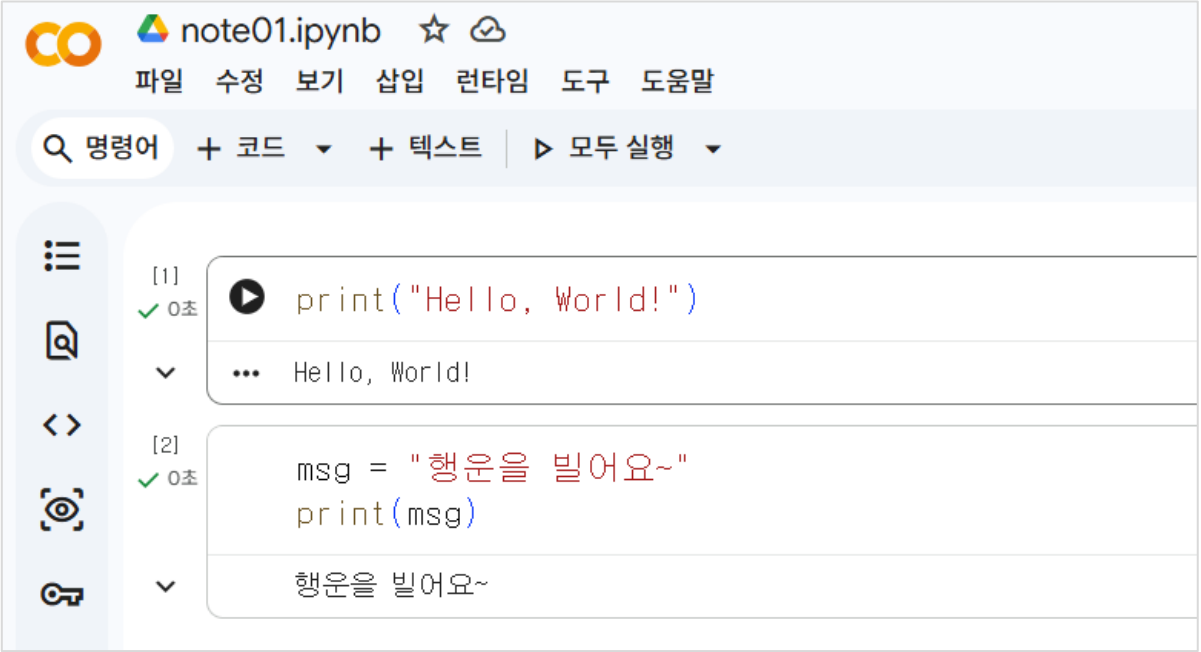

구글 코렙

❖ 새 노트 만들기

- 파일이름 > note01.ipynb

```python
import pandas as pd

df = pd.DataFrame({
    "name": ['마우스', '모니터'],
    "price": [20000, 80000]
})

df
```

	name	price
0	마우스	20000
1	모니터	80000

다음 단계: df 변수로 코드 생성 | New interactive sheet

구글 코렙

❖ 새 폴더 만들기

- 드라이브 > 내 드라이브
- + 신규 > 새폴더> 머신러닝

구글 코렙

❖ 텍스트 사용하기

- 파일 이름 : 선형회귀.ipynb
- 텍스트(버튼) > 문서의 제목을 만들때 사용

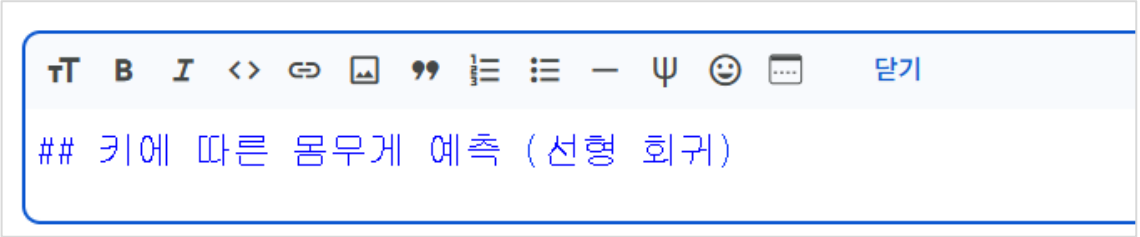

<편집화면>

shift + enter

키에 따른 몸무게 예측 (선형 회귀)

<출력화면>

❖ 드라이브 마운트

- 폴더 > 드라이브 마운트 > 드라이브 연결

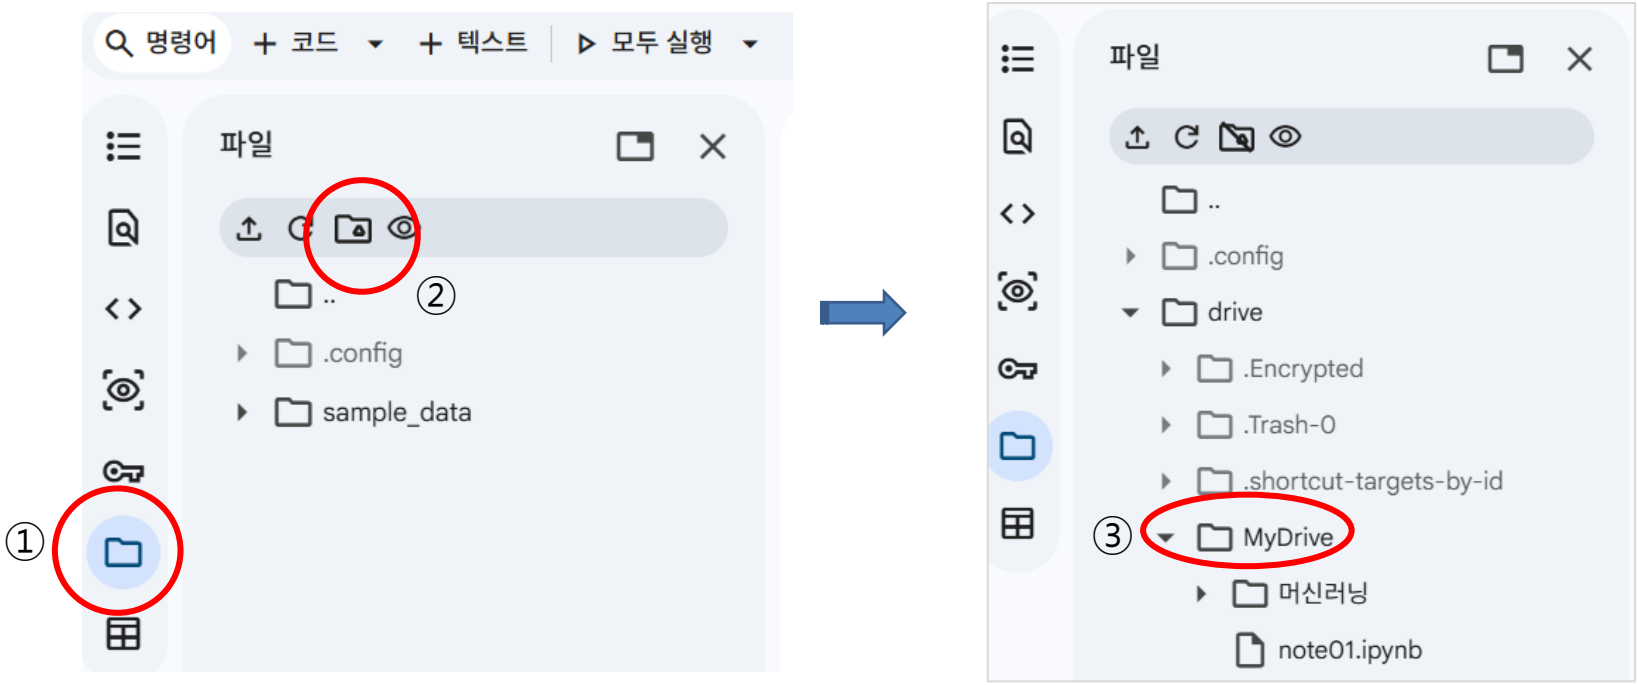

구글 코렙

❖ 훈련 데이터 업로드

- (...) 메뉴 > 업로드 > data_hw.csv

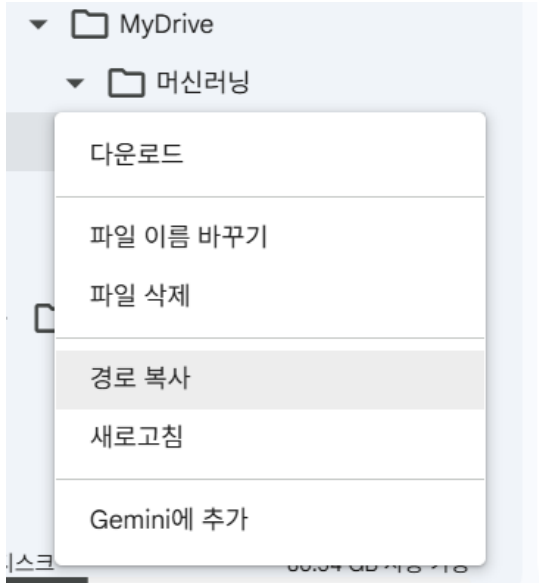

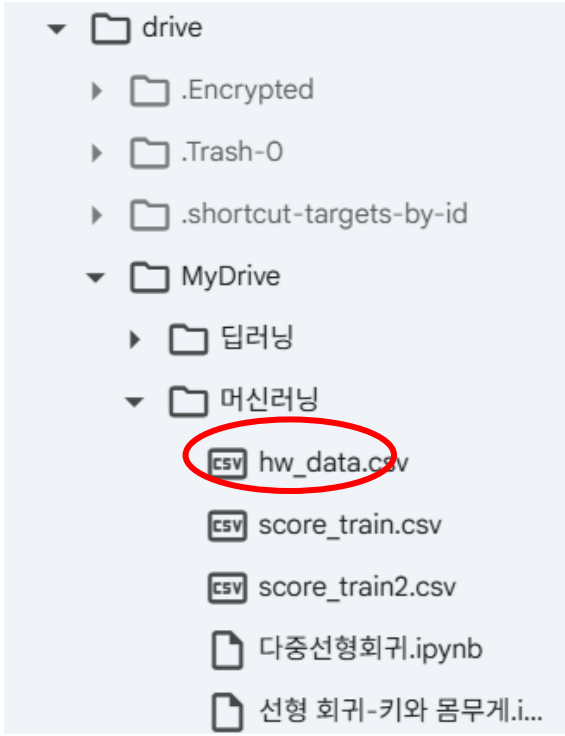

키에 따른 몸무게 예측

- **데이터 준비**

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression

# 가상의 키와 몸무게 데이터 생성
data_hw = {
    '키': [150, 160, 170, 175, 165, 155, 172, 168, 174, 158,
           162, 173, 185, 159, 167, 163, 171, 169, 180, 161],
    '몸무게': [42, 50, 70, 65, 60, 48, 68, 60, 65, 40,
               54, 67, 89, 51, 65, 60, 69, 71, 85, 53]
}
df_hw = pd.DataFrame(data_hw)

# csv 파일로 저장하기
df_hw.to_csv("/content/drive/MyDrive/머신러닝/hw_data.csv", index=False)

df_hw.head()
```

키에 따른 몸무게 예측

- **변수 선택**

변수 선택

- 독립변수 (X): 키
- 종속변수 (y): 몸무게

```
# csv 파일 읽기
df_hw = pd.read_csv("/content/drive/MyDrive/머신러닝/hw_data.csv")
print(df_hw)


# 독립 변수 '키'
X_hw = df_hw[['키']]
# 종속 변수 '몸무게'
y_hw = df_hw['몸무게']

print("X (키):₩n", X_hw.head())
print("₩ny (몸무게):₩n", y_hw.head())
```

키에 따른 몸무게 예측

- **모델 학습**

모델 학습

```
# 선형 회귀 모델 초기화
model_hw = LinearRegression()

# 모델 학습
model_hw.fit(X_hw, y_hw)

print("키-몸무게 모델 학습이 완료되었습니다.")
```

```
키-몸무게 모델 학습이 완료되었습니다.
```

키에 따른 몸무게 예측

- **모델 학습 및 예측 수행**

모델 학습

[3]
0초

```
# 선형 회귀 모델 초기화
model_hw = LinearRegression()

# 모델 학습
model_hw.fit(X_hw, y_hw)

print("키-몸무게 모델 학습이 완료되었습니다.")
```

```
키-몸무게 모델 학습이 완료되었습니다.
```

예측 수행

[4]
0초

```
pred_hw = model_hw.predict(X_hw)

print("예측 결과 (일부):₩n", pred_hw[:5])
```

```
예측 결과 (일부):
 [37.87287743 51.95425581 66.03563419 73.07632338 58.994945  ]
```

키에 따른 몸무게 예측

- **모델 시각화**

```
plt.scatter(X_hw, y_hw, label='Original Data')
plt.plot(X_hw, pred_hw, color='red', label='Regression Line')
plt.rc('font', family='NanumGothic') # 한글 글꼴 적용
plt.title('키에 따른 몸무게 선형 회귀')
plt.xlabel('키 (cm)')
plt.ylabel('몸무게 (kg)')
plt.legend()
plt.show()
```

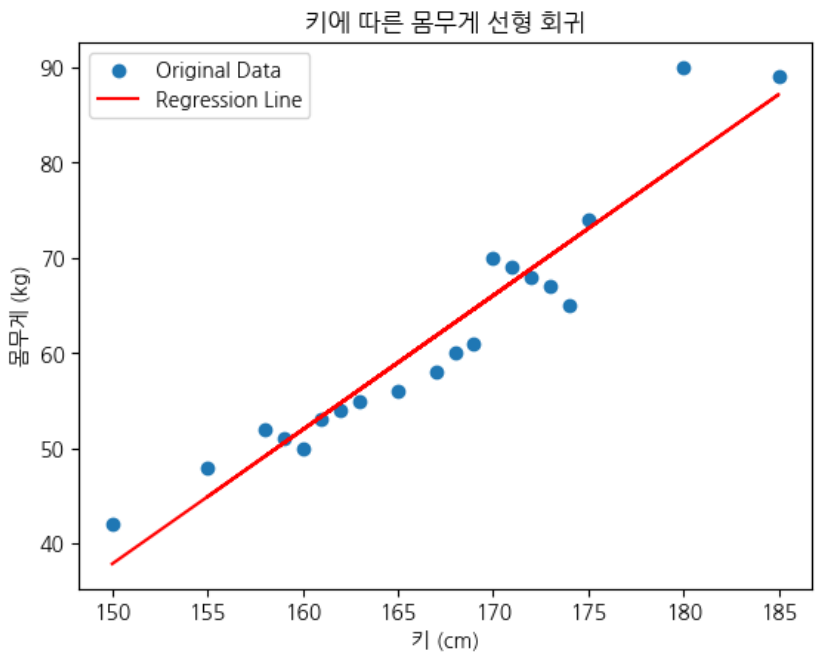

키에 따른 몸무게 예측

- **모델 시각화 – 한글 글꼴 설정**

```
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm

# Install NanumGothic font
!sudo apt-get install -y fonts-nanum
!sudo fc-cache -fv

# Add font to font manager
fm.fontManager.addfont('/usr/share/fonts/truetype/nanum/NanumGothic.ttf')

# Set the default font to NanumGothic
plt.rc('font', family='NanumGothic')

print("NanumGothic font installed and configured.")
```

키에 따른 몸무게 예측

- **성능 평가 및 몸무게 예측**

직선의 방정식 (기울기 및 y절편)

```
print(f"기울기 (Coefficient): {model_hw.coef_[0]:.4f}")
print(f"절편 (Intercept): {model_hw.intercept_:.4f}")
```

```
기울기 (Coefficient): 1.4081
절편 (Intercept): -173.3478
```

성능 평가

```
# 키-몸무게 모델 (model_hw)에 대한 성능 평가 (전체 데이터)
print(f"키-몸무게 모델 (전체 데이터) R2 Score: {model_hw.score(X_hw, y_hw):.4f}")
```

```
키-몸무게 모델 (전체 데이터) R2 Score: 0.9135
```

키가 170cm일 때 예상 몸무게

```
print(model_hw.predict([[170]]))
```

```
[66.03563419]
/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature names,
  warnings.warn(
```

키에 따른 몸무게 예측

- **데이터 세트 분리**

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression

# csv 파일 읽기
df_hw = pd.read_csv("/content/drive/MyDrive/머신러닝/hw_data.csv")
print(df_hw.head())

# 변수 선택
# X = df_hw[['키']]
X = df_hw.drop("몸무게", axis=1)
y = df_hw['몸무게']

print("X (키):₩n", X.head())
print("₩ny (몸무게):₩n", y.head())
```

```
     키  몸무게
0  150   42
1  160   50
2  170   70
3  175   65
4  165   60
X (키):
      키
0  150
1  160
2  170
3  175
4  165
```

키에 따른 몸무게 예측

- **데이터 분할**

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X, y,
                                    test_size=0.2, random_state=12) # 테스트 세트 크기를 20%로 변경

print(X_train.shape, X_test.shape, y_train.shape, y_test.shape)

# 훈련 세트와 테스트 세트 확인
print("훈련 세트 X_train:₩n", X_train.head())
print("₩n훈련 세트 y_train:₩n", y_train.head())
print("₩n테스트 세트 X_test:₩n", X_test.head())
print("₩n테스트 세트 y_test:₩n", y_test.head())
```

```
(16, 1) (4, 1) (16,) (4,)
훈련 세트 X_train:
     몸무게
14   58
16   69
10   54
8    65
5    48

훈련 세트 y_train:
 14    58
16    69
10    54
8     65
5     48
Name: 몸무게, dtype: int64
```

키에 따른 몸무게 예측

- **모델 학습**

분리된 데이터를 통한 모델 학습

```
from sklearn.linear_model import LinearRegression

# 선형 회귀 모델 객체 생성
model = LinearRegression()

# 모델 학습
model.fit(X_train, y_train)

print("모델 학습이 완료되었습니다.")
```

```
모델 학습이 완료되었습니다.
```

키에 따른 몸무게 예측

- **모델 시각화 – 훈련 데이터**

```
plt.scatter(X_train, y_train, label='train data')
plt.plot(X_train, model.predict(X_train), color='red', label='Regression Line')
plt.rc('font', family='NanumGothic') # 한글 글꼴 적용
plt.title('키에 따른 몸무게 선형 회귀 (훈련 데이터)')
plt.xlabel('키')
plt.ylabel('몸무게')
plt.legend()
plt.show()
```

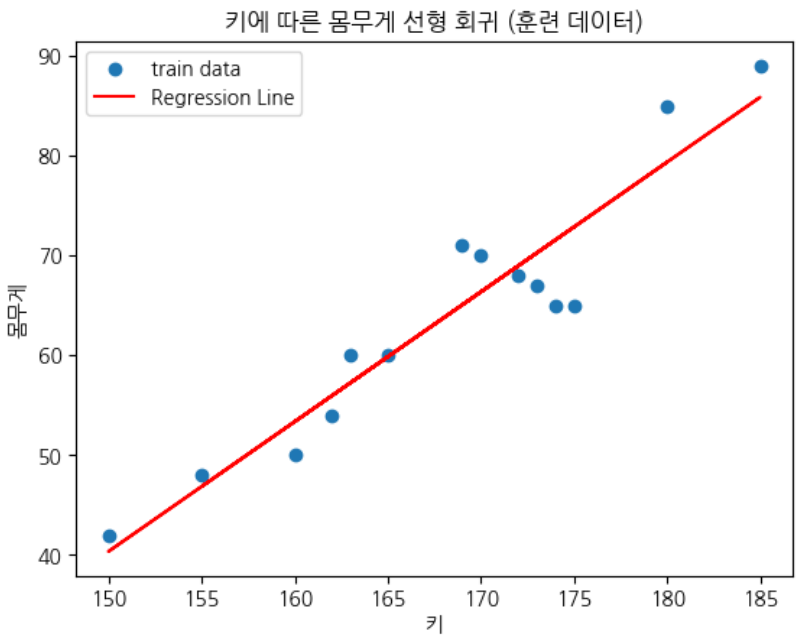

키에 따른 몸무게 예측

- **모델 시각화 – 테스트 데이터**

```
plt.scatter(X_test, y_test, label='test data') # 레이블 수정
plt.plot(X_test, model.predict(X_test), color='red', label='Regression Line')
plt.rc('font', family='NanumGothic')  # 한글 글꼴 적용
plt.title('키에 따른 몸무게 선형 회귀 (테스트 데이터)') # 제목 수정
plt.xlabel('키') # 라벨 수정
plt.ylabel('몸무게') # 라벨 수정
plt.legend()
plt.show()
```

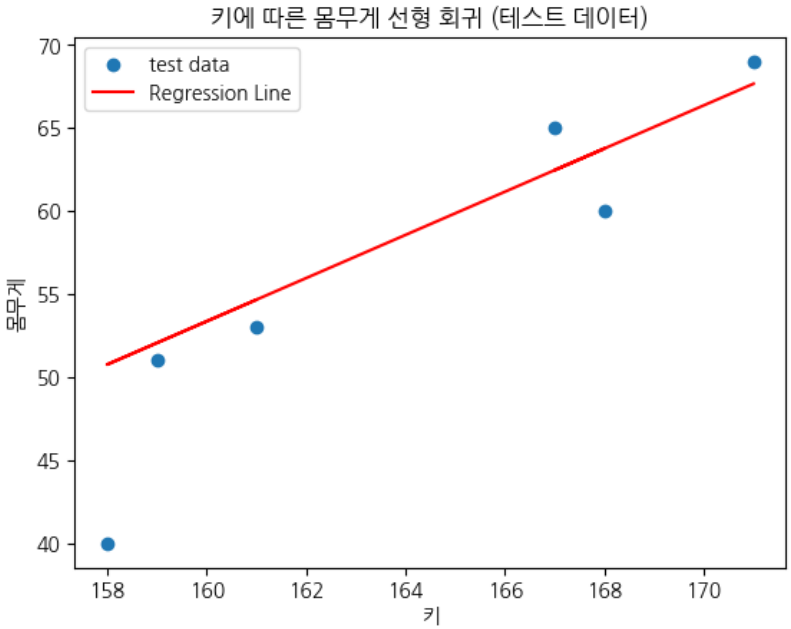

키에 따른 몸무게 예측

- **모델 성능 평가 및 예측**

모델의 성능 평가

```
model.score(X_train, y_train) #훈련세트를 통한 모델 평가
```

```
0.896152355234782
```

```
model.score(X_test, y_test) #테스트 세트를 통한 모델 평가
```

```
0.7439908761659375
```

키가 170cm일때 예상 몸무게

```
print(model.predict([[170]]))
```

```
[66.36418161]
/usr/local/lib/python3.12/dist-packages/sklearn/utils/validation.py:2739: UserWarning: X does not have valid feature nam
  warnings.warn(
```

딥러닝(Deep Learning)

- **딥러닝이란?**

딥러닝(Deep Learning)은 인공 신경망을 기반으로 하는 머신러닝의 한 분야입니다.
사람의 뇌가 작동하는 방식과 유사하게, 여러 계층(layer)의 신경망을 통해 데이터를 학습하고 복잡한 패턴을 인식하여 예측이나 분류 등의 작업을 수행합니다.

입력층 –> 은닉층 –> 은닉층 –> 출력층

딥러닝(Deep Learning)

- **인공 신경망**
  - **입력층(input layer)** – 데이터를 입력받는 층
  - **은닉층(hidden layer)** – 입력층에서 들어온 데이터가 여러 신호로 바뀌어 출력층까지 전달됨
  - **출력층(output layer)** – 출력층에 어떤 값이 전달되었는냐에 따라서 예측 값이 결정됨

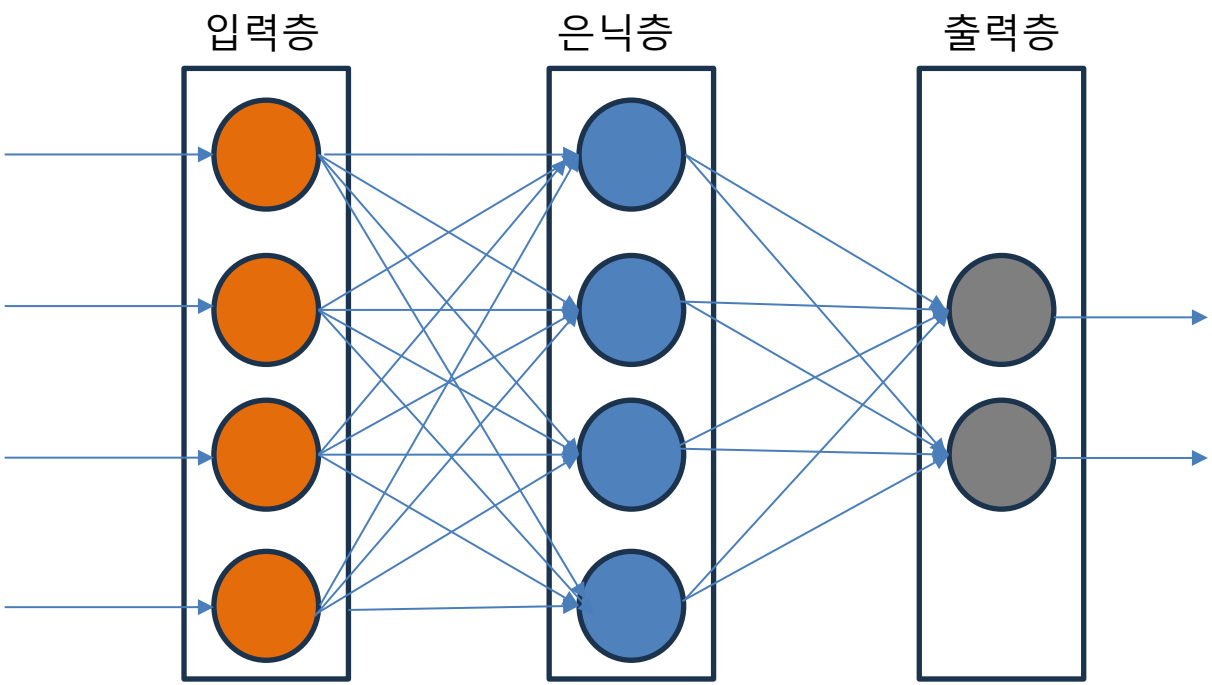

딥러닝(Deep Learning)

- **신호 전달 원리**

인공신경망에서는 단순하게 신호를 전달해 주는 것이 아니라 신호 세기를 변경해서 전달합니다.
신경망에서 중요한 용어 중 **가중치(weight)와 편향(bias)**이 있는데 이들이 바로 신호 세기를 변경하는 데 사용된다.
한 뉴런에서 다음 뉴런으로 전달되는 신호 세기는 가중치와 편향에 의해 결정됨

가중치란 그 값이 얼마나 중요한지 그렇지 않은지를 표현하기 위한 도구이고, **편향**은 한쪽으로 치우치는 값을 더할때 사용함

딥러닝(Deep Learning)

- 가중치와 편향

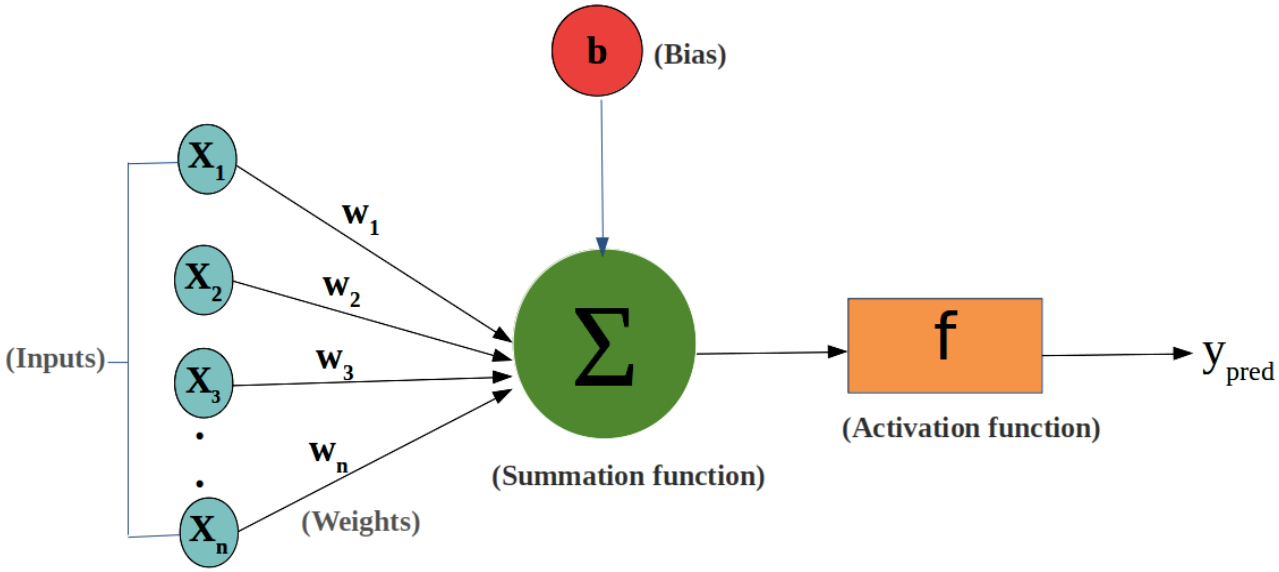

딥러닝(Deep Learning)

- **가중치와 편향**

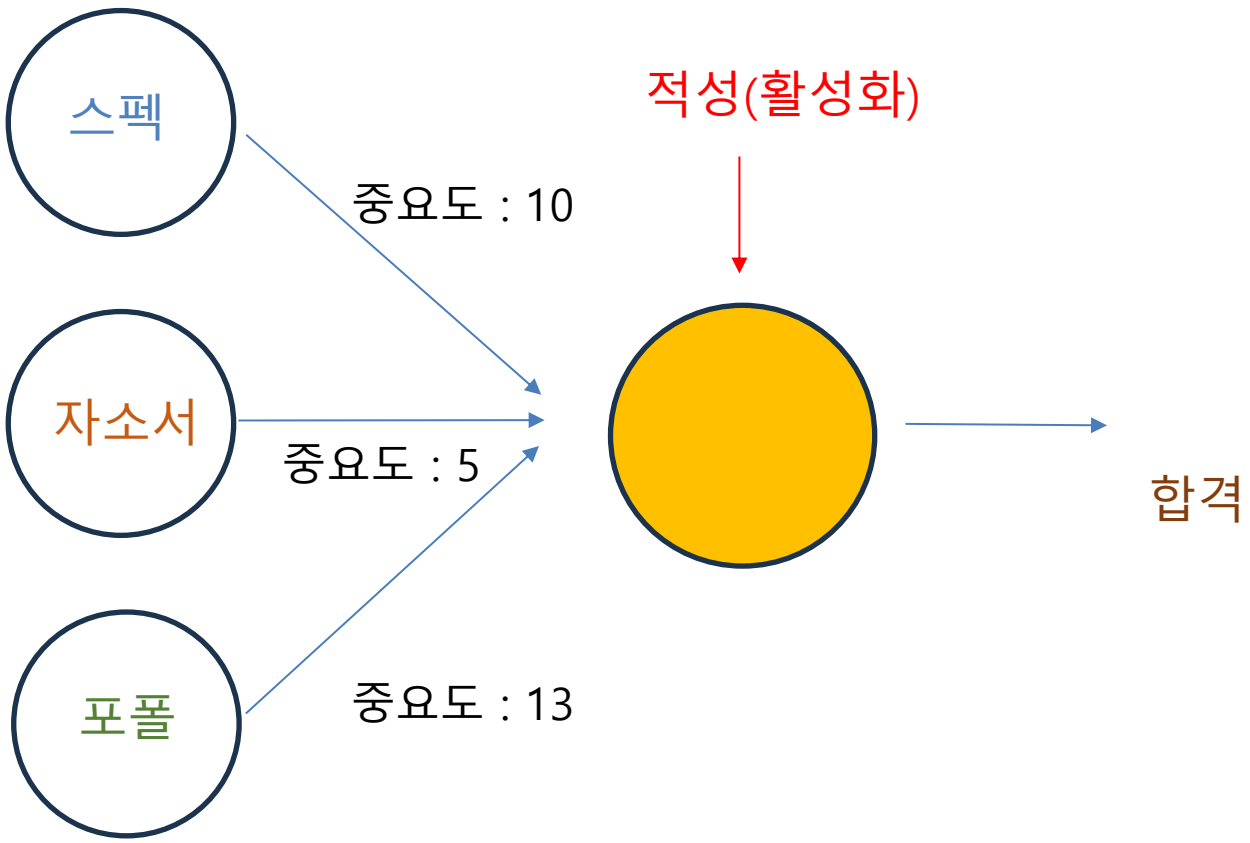

- **활성화 함수**
  - 뉴런을 활성화 할 필요가 있는지 없는 지 결정하는데 도움을 주는 함수
  - 비선형 문제를 해결하는데 중요한 역할을 한다

Sigmoid

$\sigma(x) = \frac{1}{1+e^{-x}}$

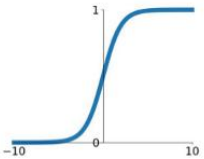

Leaky ReLU

$\max(0.1x, x)$

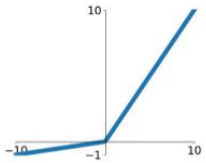

tanh

$\tanh(x)$

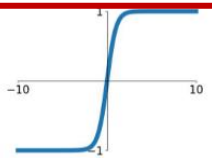

Maxout

$\max(w_1^T x + b_1, w_2^T x + b_2)$

ReLU

$\max(0, x)$

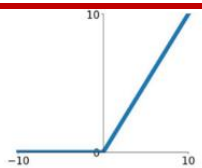

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

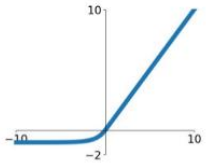

- **Softmax(소프트맥스) 함수**

소프트 맥스 함수는 사실 활성화 함수는 아니고, 인공신경망의 마지막 부분 출력층에서 주로 사용되는 함수이다.

최종 결과값을 정규화하는데 사용하는 함수가 소프트맥스 함수이다.
이 소프트맥스 함수를 사용하면 예를 들어 남자와 여자를 구분할때 2개의 노드가 100% 확률. 60%, 40%라면 총합이 1(0.6, 0.4)이 되도록 보여준다.

머신러닝과 딥러닝 비교

⚙️ 머신러닝 vs 딥러닝 한눈에 비교

구분	머신러닝	딥러닝
데이터	적어도 가능	많이 필요
특징 추출	사람이 설계	자동
계산량	적음	매우 큼
성능	보통	매우 높음

🎯 한 줄 요약

- **머신러닝**: 데이터로 규칙을 배우는 AI
- **딥러닝**: 신경망을 깊게 쌓아 더 똑똑하게 만든 머신러닝

딥러닝(Deep Learning)

- **손글씨 예측 문제**

MNIST

미국 국립표준기술연구소에서 만든 손글씨 숫자 이미지를 혼합해서 만든 데이터 셋입니다.
머신러닝 및 딥러닝 분야에서 가장 널리 사용되는 데이터셋 중 하나입니다. 주로 손으로 쓴 숫자 이미지로 구성되어 있으며, 이미지 분류 모델의 성능을 평가하는 데 사용됩니다.

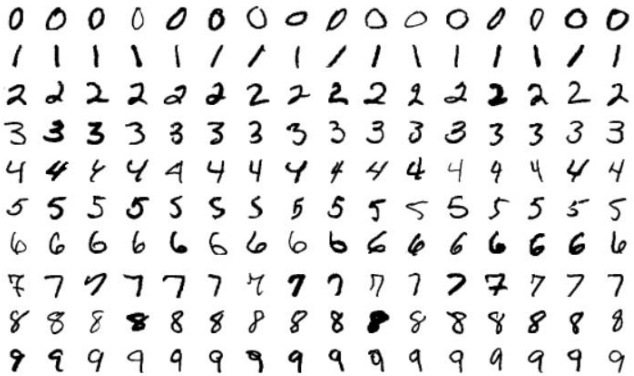

딥러닝(Deep Learning)

- **MNIST의 주요 특징**
  - **구성**: 0부터 9까지의 손글씨 숫자 이미지로 이루어져 있습니다.
  - **데이터 양**: 훈련 세트에 60,000개의 이미지, 테스트 세트에 10,000개의 이미 지가 포함되어 있습니다.
  - **이미지 크기**: 각 이미지는 28x28 픽셀의 흑백(회색조) 이미지입니다.

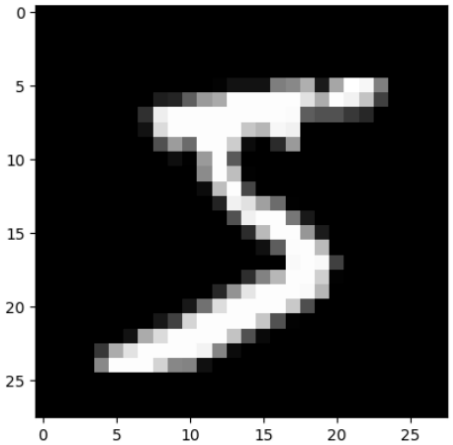

  - **용도**: 주로 이미지 분류, 특히 숫자 인식 분야에서 딥러닝 모델의 기본 성능 테스트 및 벤치마킹을 위해 활용됩니다. 간단하면서도 충분히 복잡하여 초보자들이 딥러닝을 학습하고 다양한 모델을 시도해보기 좋은 데이터셋입니다.

딥러닝(Deep Learning)

- **라이브러리 불러오기 및 데이터 준비**

```
from keras.datasets import mnist
from keras.models import Sequential
from keras.layers import Dense
import numpy as np
import matplotlib.pyplot as plt
```

```
# 데이터 준비
(X_train, y_train), (X_test, y_test) = mnist.load_data()

X_train.shape
```

```
(60000, 28, 28)
```

- **학습용 첫 데이터**

학습용 첫 데이터 보기

```
X_train[0]
```

ndarray (28, 28) show data

```
print(y_train[0])
```

```
5
```

```
plt.imshow(X_train[0], cmap="gray") # 숫자를 이미지로 출력
```

```
<matplotlib.image.AxesImage at 0x7d006afc9160>
```

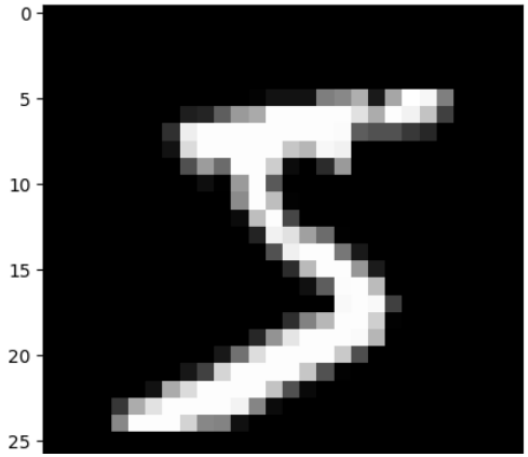

딥러닝(Deep Learning)

- **데이터 전처리**

mnist 데이터셋에서 데이터 X의 형태 바꾸기

(60000, 28, 28) -> (60000, 784)
인공 신경망의 입력층에 데이터를 넣을 때는 한 줄(행)로 만들어 넣어야 함
reshape() 사용

데이터 정규화

~~0255(색상) 사이의 값을 0~~1 사이의 값으로 바꾸기
RGB(255,255,255)- 흰색
RGB(0,0,0) - 검정색
RGB(255, 0, 0) - 빨간색

데이터를 255로 나눔 - 실수형으로 바뀜

```
X_train = X_train.reshape(60000, 784) #1차원 리스트 형태
X_test = X_test.reshape(10000, 784)

X_train = X_train / 255
X_test = X_test / 25
```

딥러닝(Deep Learning)

- **데이터 전처리**

```
X_train[0]
```

```
...
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.01176471, 0.07058824, 0.07058824,
       0.07058824, 0.49411765, 0.53333333, 0.68627451, 0.10196078,
       0.65098039, 1.        , 0.96862745, 0.49803922, 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.11764706, 0.14117647, 0.36862745, 0.60392157,
       0.66666667, 0.99215686, 0.99215686, 0.99215686, 0.99215686,
       0.99215686, 0.88235294, 0.6745098 , 0.99215686, 0.94901961,
       0.76470588, 0.25098039, 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.19215686, 0.93333333,
       0.99215686, 0.99215686, 0.99215686, 0.99215686, 0.99215686,
       0.99215686, 0.99215686, 0.99215686, 0.98431373, 0.36470588,
       0.32156863, 0.32156863, 0.21960784, 0.15294118, 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.07058824, 0.85882353, 0.99215686, 0.99215686,
       0.99215686, 0.99215686, 0.99215686, 0.77647059, 0.71372549,
       0.96862745, 0.94509804, 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.31372549, 0.61176471, 0.41960784, 0.99215686, 0.99215686,
       0.80392157, 0.04313725, 0.        , 0.16862745, 0.60392157,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.05490196,
```

- **모델 만들기**

모델 만들기

입력층 - 은닉층(256) - 은닉층2(128) - 은닉층3(64) - 출력층(10)

```
# 모델 객체 생성
model = Sequential()

model.add(Dense(units=256, input_dim=784, activation="relu")) # 입력층
model.add(Dense(units=128, activation="relu")) # 은닉층1
model.add(Dense(units=64, activation="relu")) # 은닉층2
model.add(Dense(units=10, activation="softmax")) # 출력층
model.summary() # 요약
```

```
/usr/local/lib/python3.12/dist-packages/keras/src/layers/core/dense.py:93: UserWarning: Do
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 256)	200,960
dense_1 (Dense)	(None, 128)	32,896
dense_2 (Dense)	(None, 64)	8,256
dense_3 (Dense)	(None, 10)	650

Total params: 242,762 (948.29 KB)
Trainable params: 242,762 (948.29 KB)
Non-trainable params: 0 (0.00 B)

● 모델 학습 및 예측

```python
# 모델 컴파일(최적화 함수, 손실 함수, 평가 지표)
model.compile(optimizer="adam", loss="sparse_categorical_crossentropy", metrics=["accuracy"])

# 학습
model.fit(X_train, y_train, epochs=5, batch_size=100)
```

```
Epoch 1/5
600/600 ━━━━━━━━━━━━━━━━━━━━ 8s 10ms/step - accuracy: 0.8603 - loss: 0.4748
Epoch 2/5
600/600 ━━━━━━━━━━━━━━━━━━━━ 7s 12ms/step - accuracy: 0.9697 - loss: 0.1001
Epoch 3/5
600/600 ━━━━━━━━━━━━━━━━━━━━ 4s 7ms/step - accuracy: 0.9801 - loss: 0.0637
Epoch 4/5
600/600 ━━━━━━━━━━━━━━━━━━━━ 5s 9ms/step - accuracy: 0.9858 - loss: 0.0456
Epoch 5/5
600/600 ━━━━━━━━━━━━━━━━━━━━ 6s 9ms/step - accuracy: 0.9896 - loss: 0.0320
<keras.src.callbacks.history.History at 0x7a3be77e1880>
```

```python
# 예측 - 0번째 숫자 예측하기(확률분포가 1에 가장 가까운수로 예측)
model.predict(X_test[0].reshape(1, 784))
```

```
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 88ms/step
array([[0.0000000e+00, 0.0000000e+00, 0.0000000e+00, 3.3225072e-34,
        0.0000000e+00, 0.0000000e+00, 0.0000000e+00, 1.0000000e+00,
        0.0000000e+00, 3.3698823e-38]], dtype=float32)
```

- **모델 예측**

```
# 예측 결과 - 0, 1로 출력
predictions = model.predict(X_test[0].reshape(1, 784))
predicted_class = np.argmax(predictions)

output_array = np.zeros(10, dtype=int)
output_array[predicted_class] = 1

print(output_array)
```

```
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 49ms/step
[0 0 0 0 0 0 0 1 0 0]
```

```
print(np.argmax(model.predict(X_test[0].reshape(1, 784))))
```

```
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 37ms/step
7
```